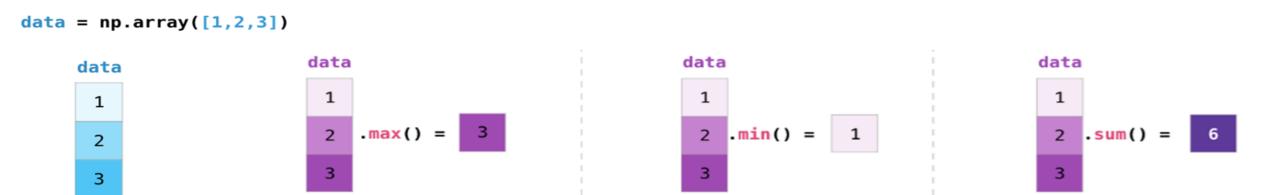
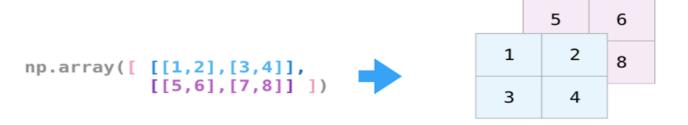
## 4. 에너지 데이터 분석 실습

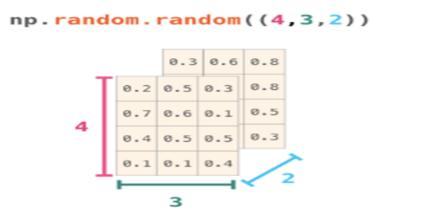


### 념파이(Numpy)

NumPy(Numerical Python)는 데이터 분석을 포함해 수학과 과학연산을 위한 파이썬 기본 패키지로 고성능의 다차원 배열 객체와 다양한 객체에 대해 고속 연산을 가능하게 합니다.









### 넘파이(Numpy)

```
import numpy as np
                                           [Out]
lst = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]
                                           Mean: 5.5
arr = np.array(lst)
                                           Median: 5.5
                                           Range (Max - min): 9
arr
[Out] array([ 1, 2, 3, 4, 5, 6, 7, 8, 9, 10])
                                           Standard deviation: 2.87228132323
arr.mean()
                                           80th percentile: 8.2
[Out] 5.5
                                           0.2-quantile: 2.8000000000000003
print('Mean:', arr.mean())
print('Median:', np.median(arr))
print('Range (Max - min):', np.ptp(arr))
print('Standard deviation:', arr.std())
print('80th percentile:', np.percentile(arr, 80))
print('0.2-quantile:', np.quantile(arr, 0.2))
```

Pandas는 데이타 분석을 위해 널리 사용되는 파이썬 라이브러리 패키지입니다. 행과 열로 이루어진 데이터프레임 자료구조를 사용하여, 데이터 분석에 있어 높은 수준의 성능을 발휘합니다.

#### ■ 데이터프레임(DataFrame)

컬럼명(Column Names)

|                |            | power_usage | gas_usage | water_usage |  |  |
|----------------|------------|-------------|-----------|-------------|--|--|
| 인덱스<br>(Index) | 2022-05-01 | 86          | 98        | 84          |  |  |
|                | 2022-05-02 | 70          | 31        | 88          |  |  |
|                | 2022-05-03 | 0           | 29        | 51          |  |  |
|                | 2022-05-04 | 32          | 77        | 75          |  |  |
|                | 2022-05-05 | 57          | 48        | 17          |  |  |
|                |            | <u> </u>    |           |             |  |  |
|                |            |             | 데이터       |             |  |  |
|                |            | 데이터         |           |             |  |  |

#### Pandas 라이브러리 임포트

import pandas as pd

#### ■ 데이터프레임 생성

#### ■ 데이터 확인

df, head()

| ar mead()  |             |           |             |  |  |  |
|------------|-------------|-----------|-------------|--|--|--|
|            | power_usage | gas_usage | water_usage |  |  |  |
| 2022-05-01 | 86          | 98        | 84          |  |  |  |
| 2022-05-02 | 70          | 31        | 88          |  |  |  |
| 2022-05-03 | 0           | 29        | 51          |  |  |  |
| 2022-05-04 | 32          | 77        | 75          |  |  |  |
| 2022-05-05 | 57          | 48        | 17          |  |  |  |

df.tail()

|            | power_usage | gas_usage | water_usage |
|------------|-------------|-----------|-------------|
| 2022-05-27 | 90          | 84        | 63          |
| 2022-05-28 | 39          | 33        | 29          |
| 2022-05-29 | 5           | 77        | 72          |
| 2022-05-30 | 42          | 73        | 8           |
| 2022-05-31 | 54          | 27        | 3           |

#### ■ 자료구조 파악

dtypes: int64(3)

memory usage: 992.0 bytes

#### df.info()

#### ■ 데이터 타입 확인

#### df.dtypes

| power_usage   | int64 |
|---------------|-------|
| gas_usage     | int64 |
| water_usage   | int64 |
| dtyne: object |       |

#### ■ Null 데이터 확인

#### df.isnull().sum()

power\_usage 0
gas\_usage 0
water\_usage 0
dtype: int64

#### ■ 통계 정보

df.describe()

|             | power_usage | gas_usage | water_usage |
|-------------|-------------|-----------|-------------|
| count       | 31.000000   | 31.000000 | 31.000000   |
| mean        | 45.161290   | 52.193548 | 52.161290   |
| std         | 26.669704   | 31.679036 | 30.625803   |
| min         | 3.000000    | 4.000000  | 0.000000    |
| 25%         | 29.000000   | 22.500000 | 18.500000   |
| 50%         | 41.000000   | 54.000000 | 57.000000   |
| <b>75</b> % | 61.500000   | 84.000000 | 76.000000   |
| max         | 97.000000   | 99.000000 | 99.000000   |

#### ■ 데이터 상관관계 분석

df.corr()

|             | power_usage | gas_usage | water_usage |
|-------------|-------------|-----------|-------------|
| power_usage | 1.000000    | -0.187838 | 0.073957    |
| gas_usage   | -0.187838   | 1.000000  | 0.007285    |
| water_usage | 0.073957    | 0.007285  | 1.000000    |

#### ■ 새 컬럼 생성하기

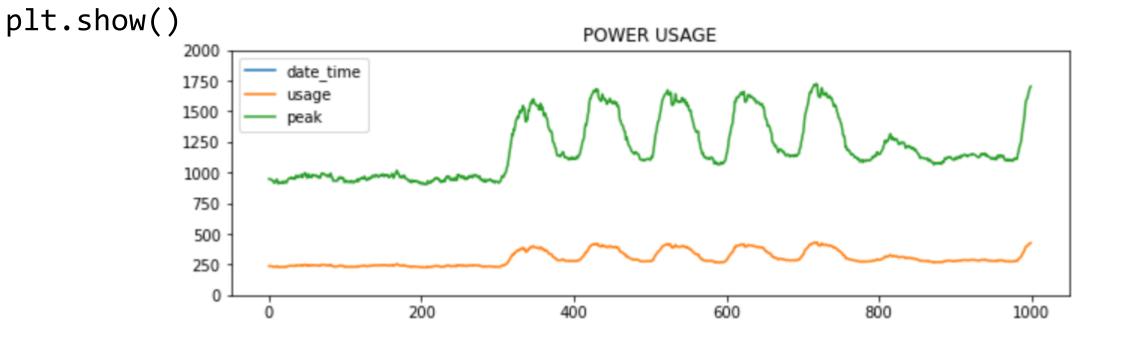
```
df['energy_usage'] = df['power_usage'] + df['gas_usage']
df['date'] = pd.to_datetime(df.index, format= '%Y-%m-%d')
df['day_of_week'] = df['date'].dt.day_name()
print(df)
```

|            | power_usage | gas_usage | water_usage | energy_usage | date       | day_of_week |
|------------|-------------|-----------|-------------|--------------|------------|-------------|
| 2020-01-01 | 95          | 86        | 64          | 181          | 2020-01-01 | Wednesday   |
| 2020-01-02 | 31          | 82        | 2           | 113          | 2020-01-02 | Thursday    |
| 2020-01-03 | 77          | 16        | 55          | 93           | 2020-01-03 | Friday      |
| 2020-01-04 | 43          | 4         | 0           | 47           | 2020-01-04 | Saturday    |
| 2020-01-05 | 44          | 79        | 57          | 123          | 2020-01-05 | Sunday      |
| 2020-01-06 | 27          | 63        | 52          | 90           | 2020-01-06 | Monday      |
| 2020-01-07 | 45          | 33        | 16          | 78           | 2020-01-07 | Tuesday     |

#### ■ 파일에서 데이터를 로드하는 방법

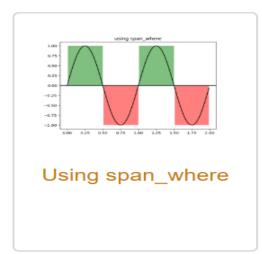
```
# df_energy = pd.read_csv('data.csv')
df_energy = pd.read_csv(
'https://raw.githubusercontent.com/kgpark88/energy-bigdata-analysis/master/data.csv')
```

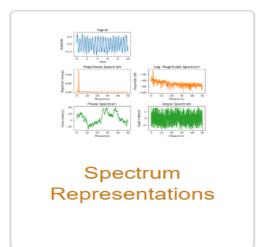
df\_energy.plot(title='POWER USAGE', figsize=(10, 3), ylim=(0,2000))



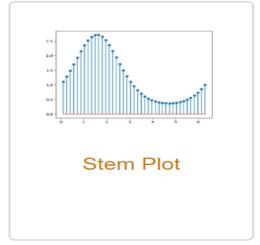
### 맷플롯립(Matplotlib)

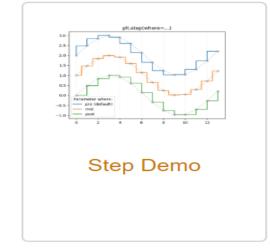
#### 파이썬에서 데이터를 차트나 플롯(Plot)으로 그려주는 라이브러리 패키지로서 가장 많이 사용되는 데이타 시각화(Data Visualization) 패키지입니다.

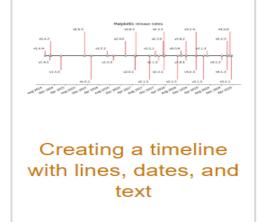


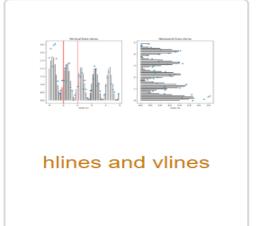












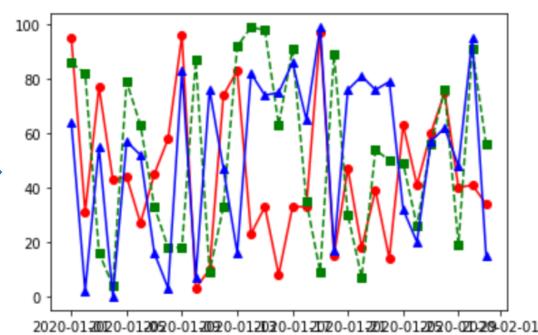


### 맷플롯립(Matplotlib)

#### ■ 라이브러리 임포트

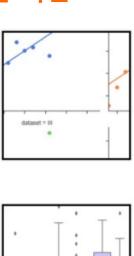
import matplotlib.pyplot as plt

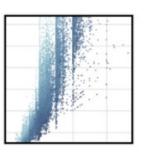
#### ■ 선 그래프

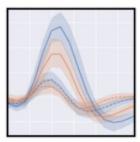


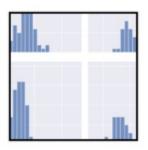
### 씨본(Seaborn)

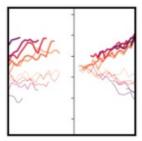
#### Matplotlib을 기반으로 다양한 색상 테마와 통계용 차트 등의 기능을 추가한 시각화 패키지입니다.

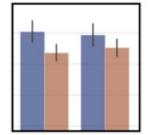


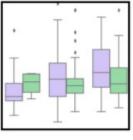


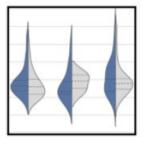


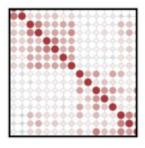


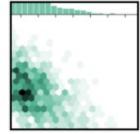


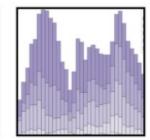


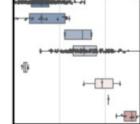


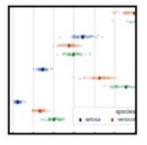




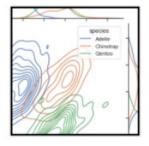




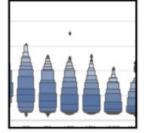














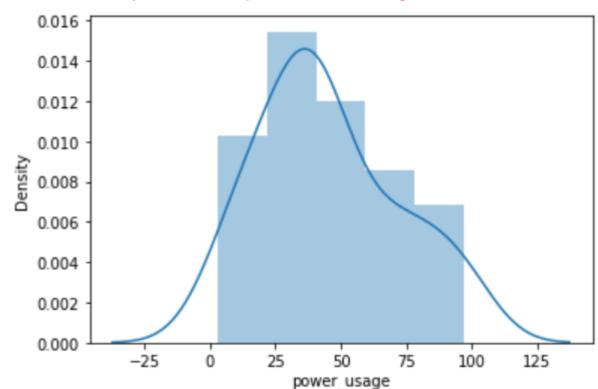
### 씨본(Seaborn)

■ 라이브러리 임포트

import seaborn as sns

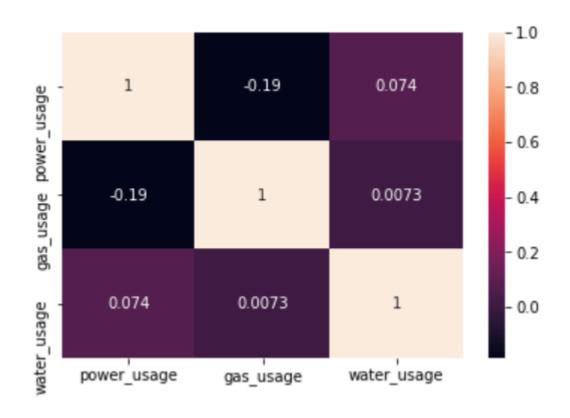
■ 분포 플롯

sns.distplot(df['power usage'])



#### ■ 히트맵(상관관계)

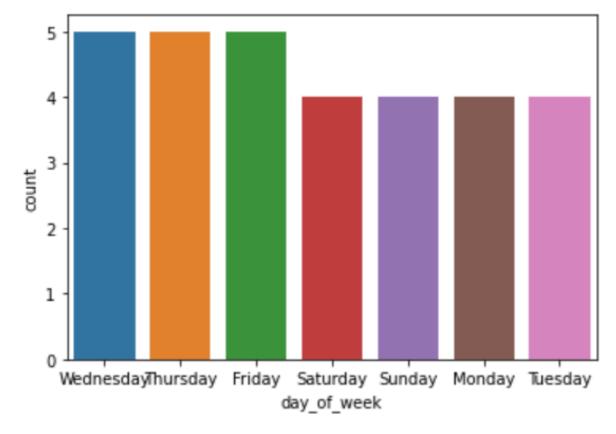
sns.heatmap(df.corr(), annot=True)



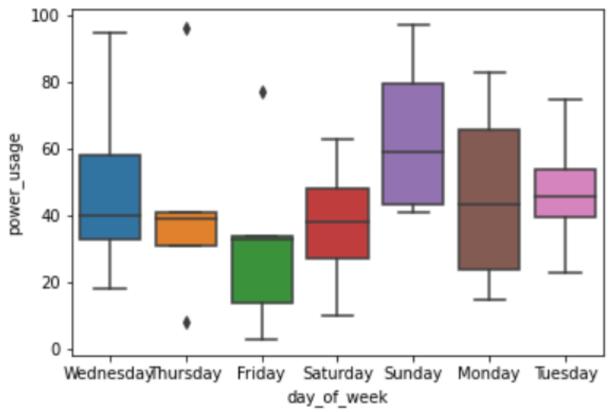
### 씨본(Seaborn)

#### ■ 카운트 플롯

sns.countplot(x='day\_of\_week', data=df)

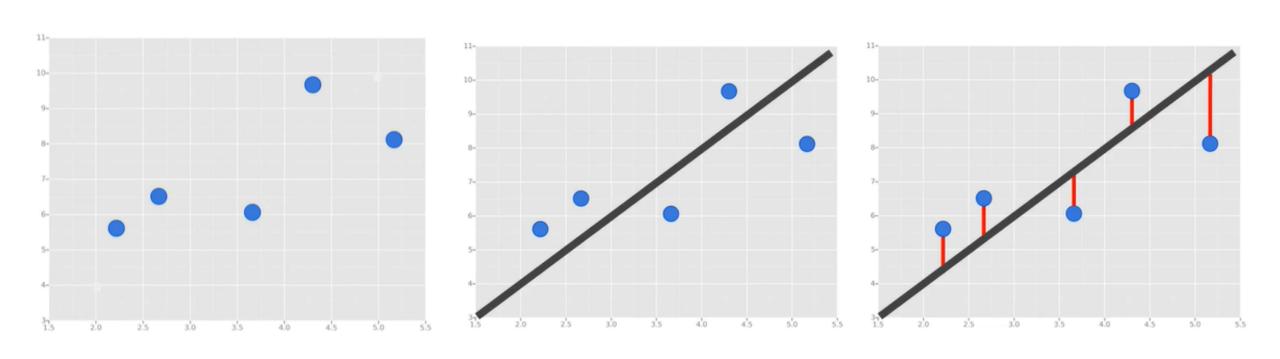


#### ■ 박스 플롯



### 선형 회귀

종속 변수 y와 한 개 이상의 독립 변수 X와의 선형 상관 관계를 모델링 하는 회귀분석 기법



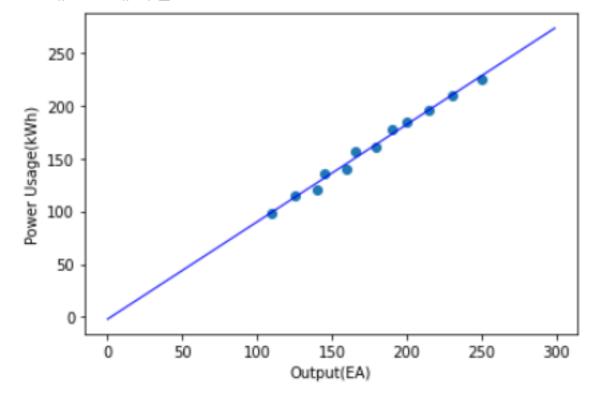
### 선형 회귀

```
import numpy as np
from scipy import stats
import matplotlib.pyplot as plt
# 생산량
output = [110, 125, 140, 145, 160, 166, 179, 190, 200, 215, 230, 250]
# 전력사용량
power_usage = [98, 115, 120, 136, 140, 156, 160, 177, 185, 195, 210, 225]
# p-value : 유의 확률, 일반적으로 0.05 미만일 때 유의미
slope, intercept, r value, p value, stderr = stats.linregress(output, power usage)
```

### 선형 회귀

```
# 생산량 134개일 때 전기사용량 예측
product = 134
print("기울기(slope): ", slope)
print("절편(intercept) : ", intercept)
print("상관계수(r_value) : ", r_value)
print("유의확률(p_value) : ", p_value )
print("{}개 => 예측량 {}kWh".format(
     product, product*slope + intercept))
plt.scatter(output, power_usage)
x = np.arange(0, 300)
y = [(slope*num + intercept) for num in x]
plt.plot(x, y, 'b', lw=1)
plt.xlabel("Output(EA)")
plt.ylabel("Power Usage(kWh)")
plt.show()
```

기울기(slope): 0.9200457304535211 절편(intercept): -2.024707604744151 상관계수(r\_value): 0.9950415352828844 유의확률(p\_value): 2.3409613797567155e-11 134개 => 예측량 121.26142027602768k₩h



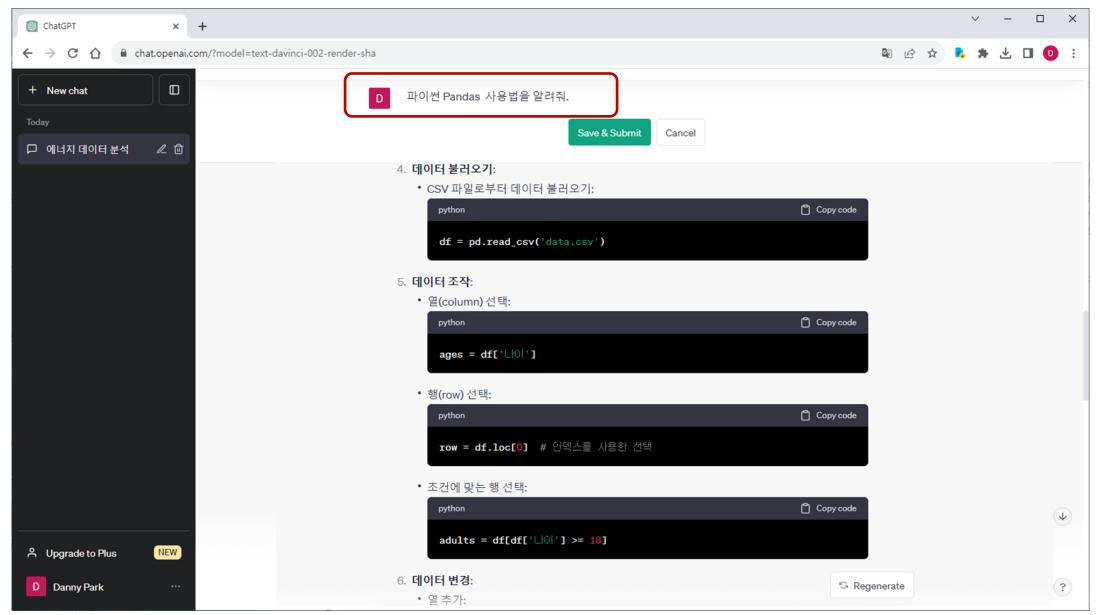
### 에너지 데이터 분석 실습



energy\_data\_analysis.ipynb

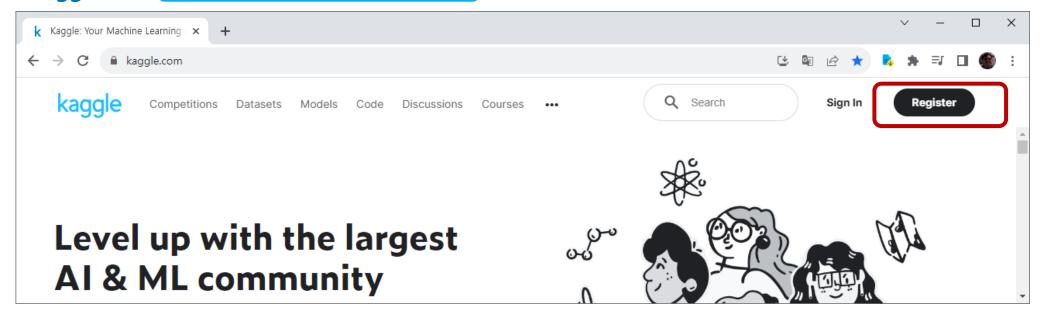
charts.ipynb

### 에너지 데이터 분석 실습



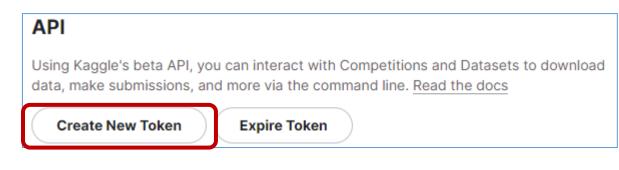
### Kaggle 사용

■ kagge 가입 https://www.kaggle.com/



#### kgggle.json 다운로드

https://www.kaggle.com/settings → API

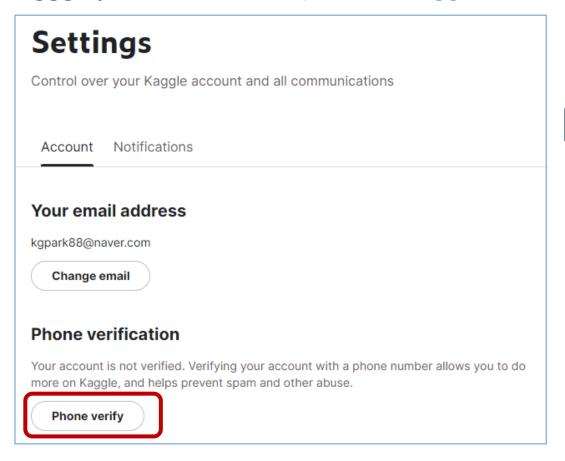


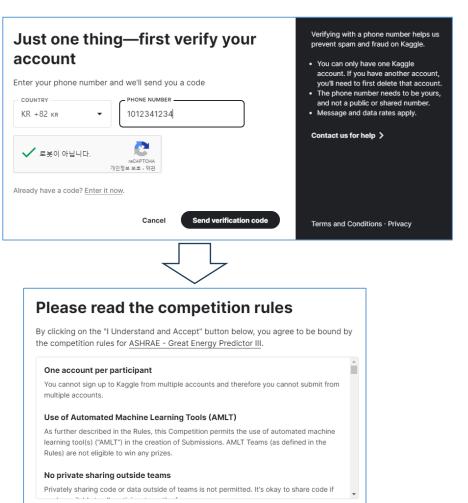


Ensure kaggle.json is in the location ~/.kaggle/kaggle.json to use the API.

### Kaggle 사용

- **■** kaggle Phone verification
- kgggle.json 다운로드 : <a href="https://www.kaggle.com/settings">https://www.kaggle.com/settings</a> → Phone verification

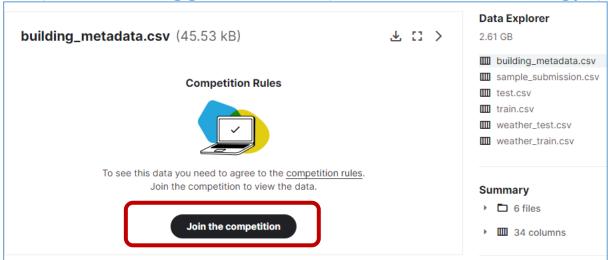




I Understand and Accept

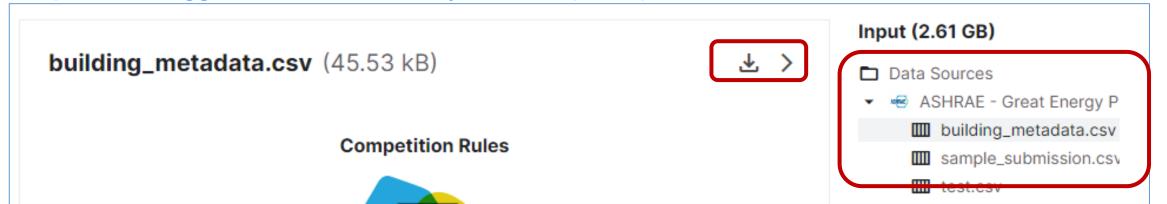
#### ■ Competition 참여

https://www.kaggle.com/competitions/ashrae-energy-prediction/data



#### ■ 데이터셋

https://www.kaggle.com/code/sudalairajkumar/simple-exploration-notebook-ashrae/data





energy\_data\_exploration.ipynb

- kaggle 패키지 설치 !pip install kaggle
- kaggle API 키 업로드 from google.colab import files

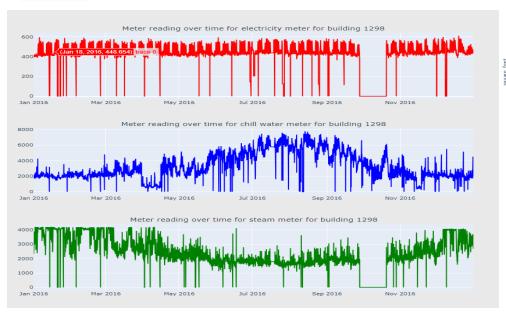
```
files.upload()
```

- !mkdir ~/.kaggle
  !cp kaggle.json ~/.kaggle/
  !chmod 600 ~/.kaggle/kaggle.json
- kaggle 패키지 설치

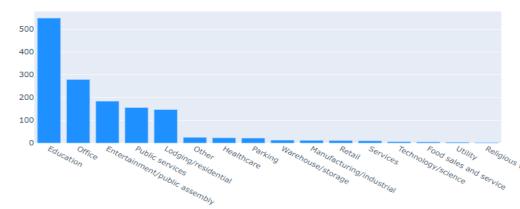
!kaggle competitions download -c ashrae-energy-prediction



#### energy\_data\_exploration.ipynb



Primary use of Buildings - Count



1/2016

3/2016

5/2016

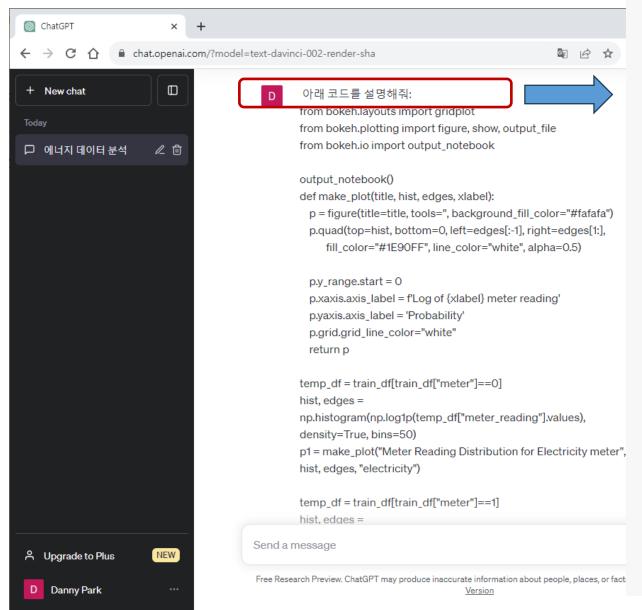


7/2016

9/2016

11/2016

1/2017





이 코드는 Bokeh 라이브러리를 사용하여 시각화를 생성하는데 관련된 것으로 보입니다. Bokeh는 대화형 시각화 라이브러리로, 웹 브라우저에서 그래프와 플롯을 생성하고 상호 작용 할 수 있는 기능을 제공합니다. 코드의 내용을 하나씩 살펴보겠습니다.

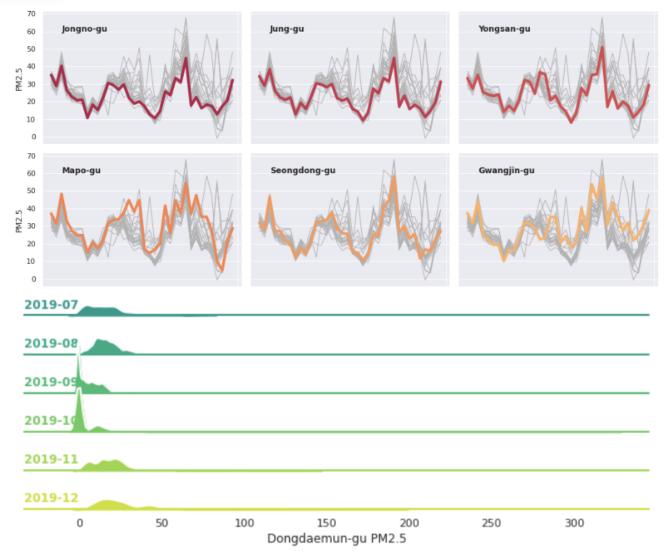
- 1. `from bokeh.layouts import gridplot`: Bokeh의 gridplot 레이아웃을 사용하기 위해 필요한 모듈을 가져옵니다.
- 2. `from bokeh.plotting import figure, show, output\_file`: 그래프 생성을 위한 'figure`와 시각화를 보여주는 'show' 함수, 그리고 출력 파일을 생성하기 위한 'output\_file` 함수를 가져옵니다.
- 3. **`from bokeh.io import output\_notebook`**: Jupyter Notebook에서 Bokeh 시각화를 인라 인으로 보여주기 위한 함수를 가져옵니다.
- 4. `output\_notebook()`: Jupyter Notebook에서 Bokeh 플롯을 인라인으로 보여줍니다.
- 5. `make\_plot(title, hist, edges, xlabel)`:시각화를 생성하는 함수입니다. `title`은 그래프 제목, `hist`는 히스토그램 데이터, `edges`는 히스토그램의 구간 경계, `xlabel`은 x 축 레이블을 의미합니다. 함수는 Bokeh의 `figure` 객체를 생성하고 히스토그램 데이터를 기반으로 그래프를 그립니다. 그래프의 스타일, 레이블 등을 설정한 후 `figure` 객체를 반환합니다.
- 6. 다음 코드 블록은 `train\_df` 데이터프레임에서 각각 다른 `metex` 값에 따라 미터별 사용량 분포를 시각화합니다. 각각의 미터 유형에 대해 `hist` (히스토그램 데이터)와 `edges` (구간 경계)를 계산하고, 해당 데이터를 `make\_plot` 함수를 사용하여 그래프로 그립니다.
- 7. 마지막으로 `gridplot`을 사용하여 각 그래프를 그리드 형태로 배열하고, `show` 함수를 호출하여 그리드를 보여줍니다. `gridplot`은 여러 개의 그래프를 원하는 형태로 배열하는데 사용됩니다. `ncols`는 열의 개수, `width`와 `height`는 각 그래프의 크기를 지정하는 옵션입니다.

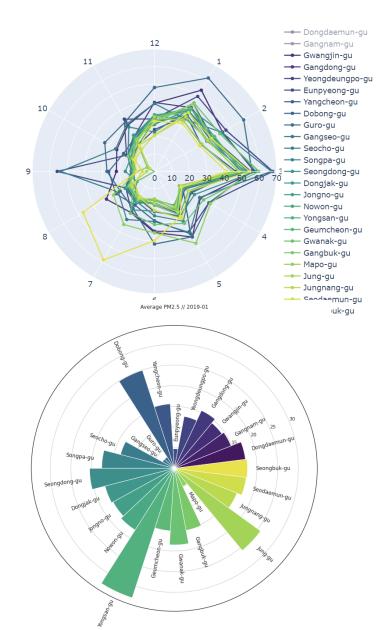
이 코드는 Bokeh를 사용하여 서로 다른 미터 유형의 사용량 분포를 시각화하고 그것들을 그리 드로 배열하여 한 번에 비교할 수 있도록 하는 것입니다.

### 다중 시계열 데이터 분석 시각화 실습



#### multiple\_time\_series\_data\_analysis.ipynb





### 노코드(No Code) 데이터 분석



https://docs.kanaries.net/ko/pygwalker/use-pygwalker-with-streamlit

#### ■ 패키지 설치

pip install pandas
pip install pygwalker
pip install streamlit

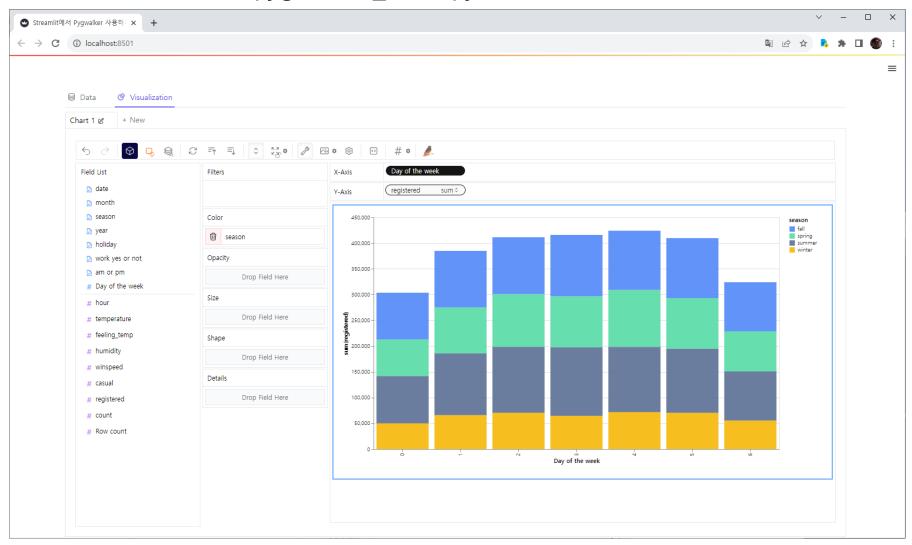
#### pygwalker\_demo.py

```
import pygwalker as pyg
    import pandas as pd
    import streamlit.components.v1 as components
    import streamlit as st
    # Streamlit 페이지의 너비 조정
    st.set page config(
        page title="Streamlit에서 Pygwalker 사용하기",
        layout="wide"
12
    # 제목 추가
    st.title("Streamlit에서 Pygwalker 사용하기")
    # 데이터 가져오기
    df = pd.read_csv("public-datasets/bike_sharing_dc.csv")
    # Pygwalker를 사용하여 HTML 생성
    pyg_html = pyg.walk(df, return_html=True)
    # Streamlit 앱에 HTML 임베드
    components.html(pyg_html, height=1000, scrolling=True)
```

■ 실행

### 노코드(No Code) 데이터 분석

■ 실행 streamlit run pygwalker\_demo.py



# THANKYOU

kgpark88@gmail.com