5. 빅데이터 플랫폼

박경규

빅데이터 플랫폼 개요

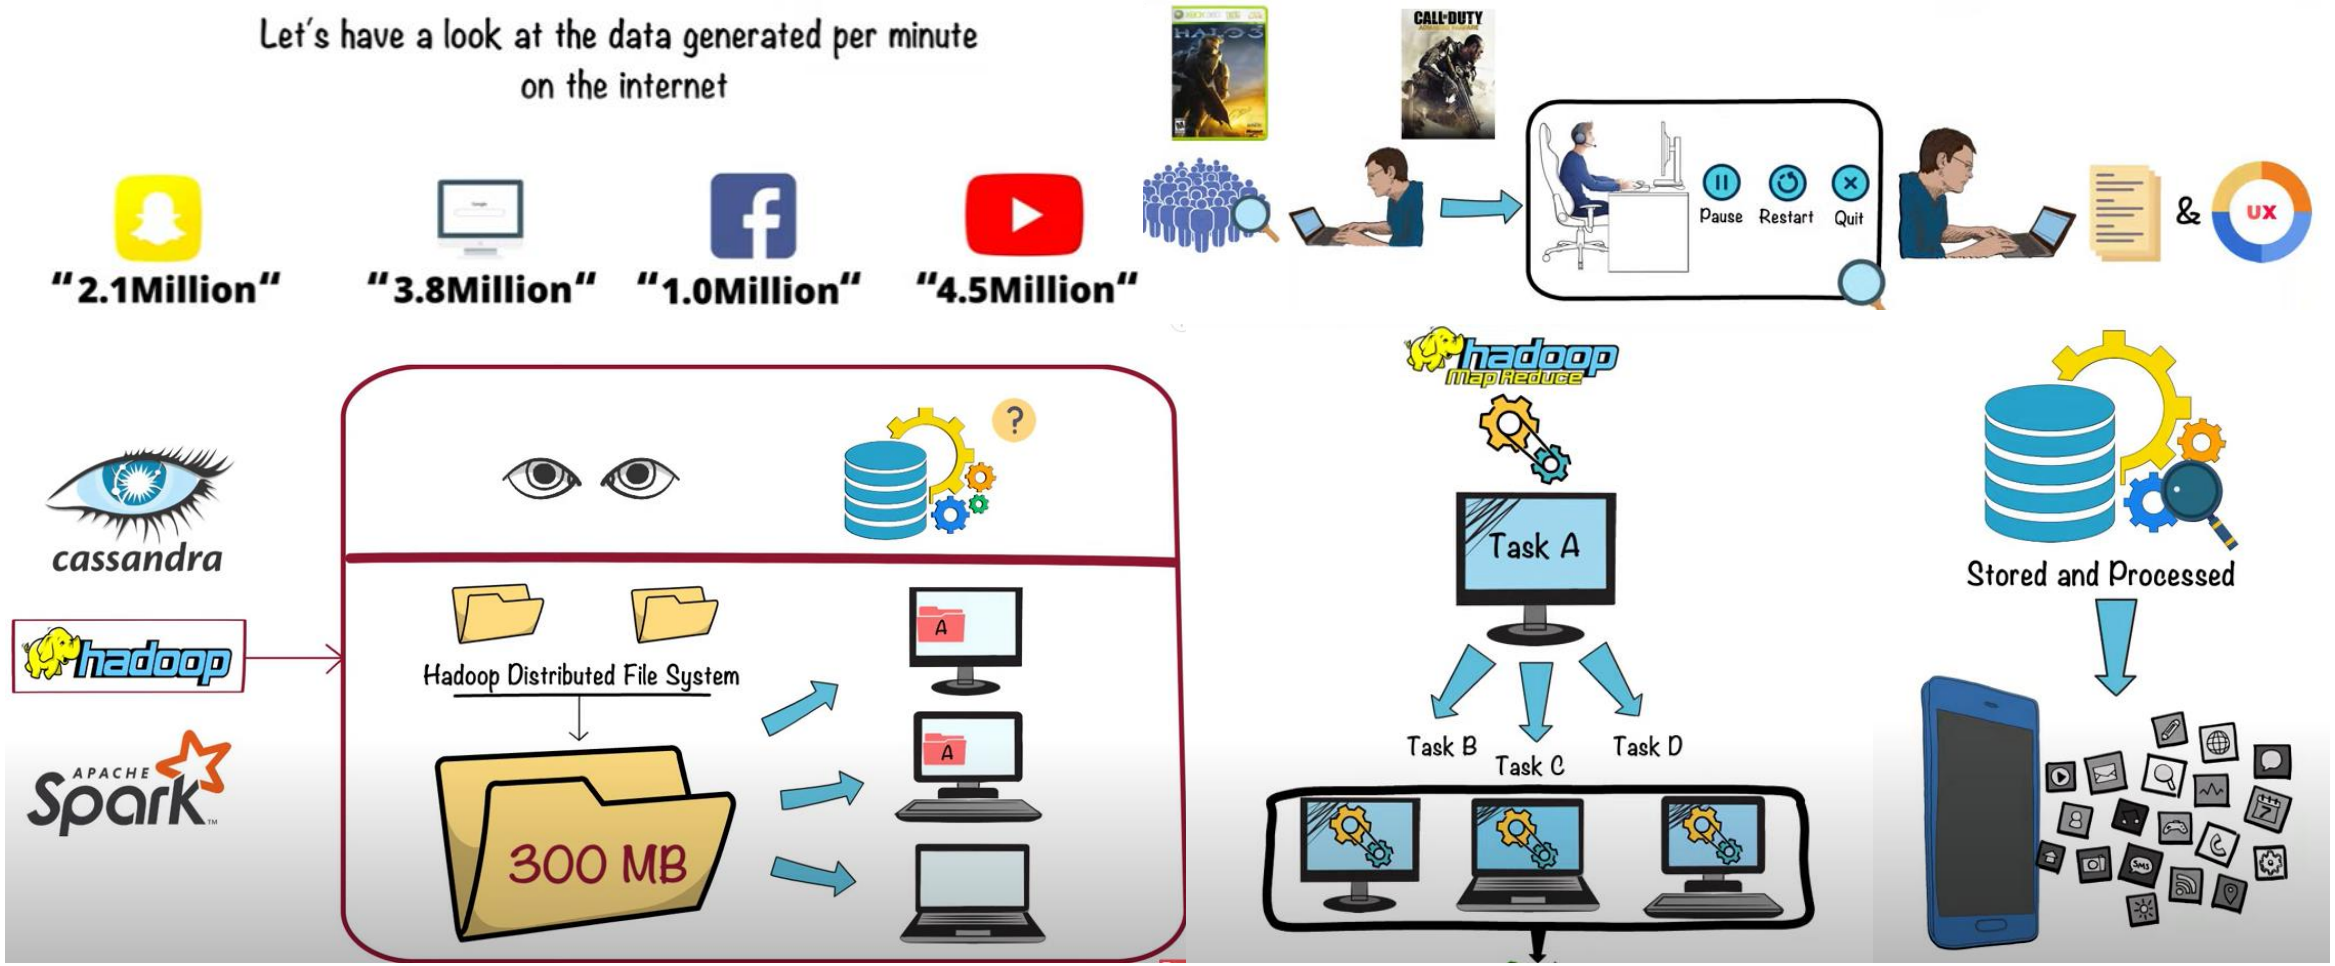

https://youtu.be/bAyrObl7TYE

데이터 형태

정형 데이터

- 형태가 있으며 연산 가능함. 주로 관계형 데이터베이스에 저장됨
- 데이터 수집 난이도가 낮음
- 내부 시스템인 경우가 대부분임
- 파일 형태의 스프레드시트라도 내부에 형식을 가지고 있어 처리가 쉬운 편임
- EX) 관계형 데이터베이스, 스프레드시트, CSV 등

반정형 데이터

- 형태(스키마, 메타데이터)가 있으며 연산이 불가능
- 주로 파일에 저장됨
- 데이터 수집 난이도가 중간
- 보통 API 형태로 제공되기 때문에 데이터 처리기술이 요구됨
- EX) XML, HTML, 로그형태(웹로그, 센서데이터), Machine Data 등

비정형 데이터

- 형태가 없으며, 연산이 불가능함
- 주로 NoSQL에 저장됨
- 데이터 수집 난이도가 높음
- 텍스트 마이닝 혹은 파일일 경우 파일을 데이터 형태로 파싱해야 하기 때문에 수집 데이터 처리가 어려움
- EX) 소셜데이터(트위터, 페이스북), 이메일, 보고서

비정형 데이터

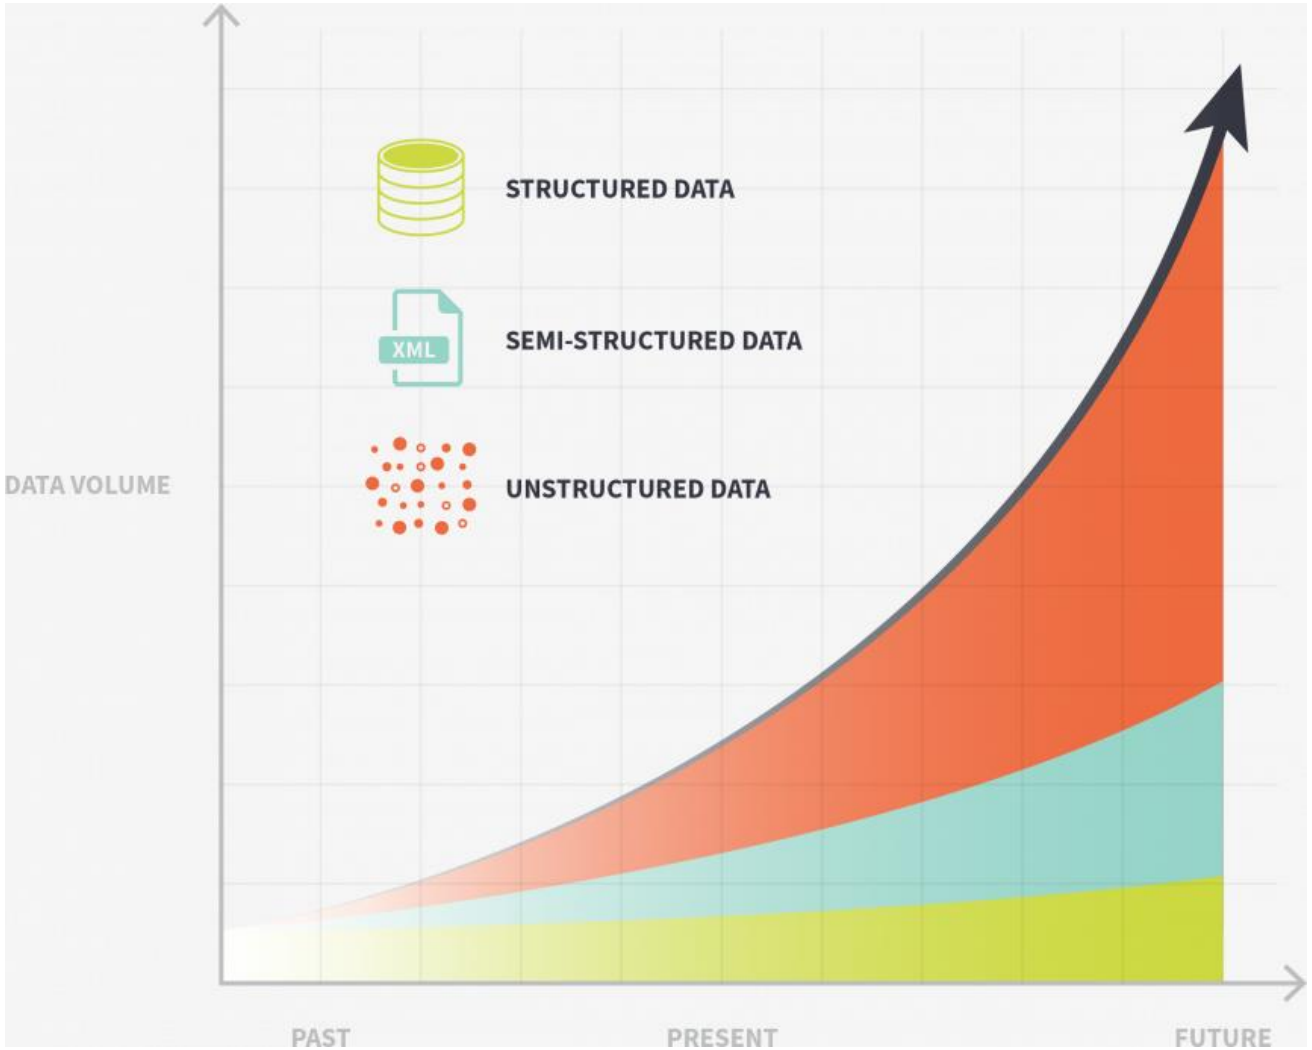
STRUCTURED DATA
XML
SEMI-STRUCTURED DATA
UNSTRUCTURED DATA
DATA VOLUME
PAST
PRESENT
FUTURE

NoSQL

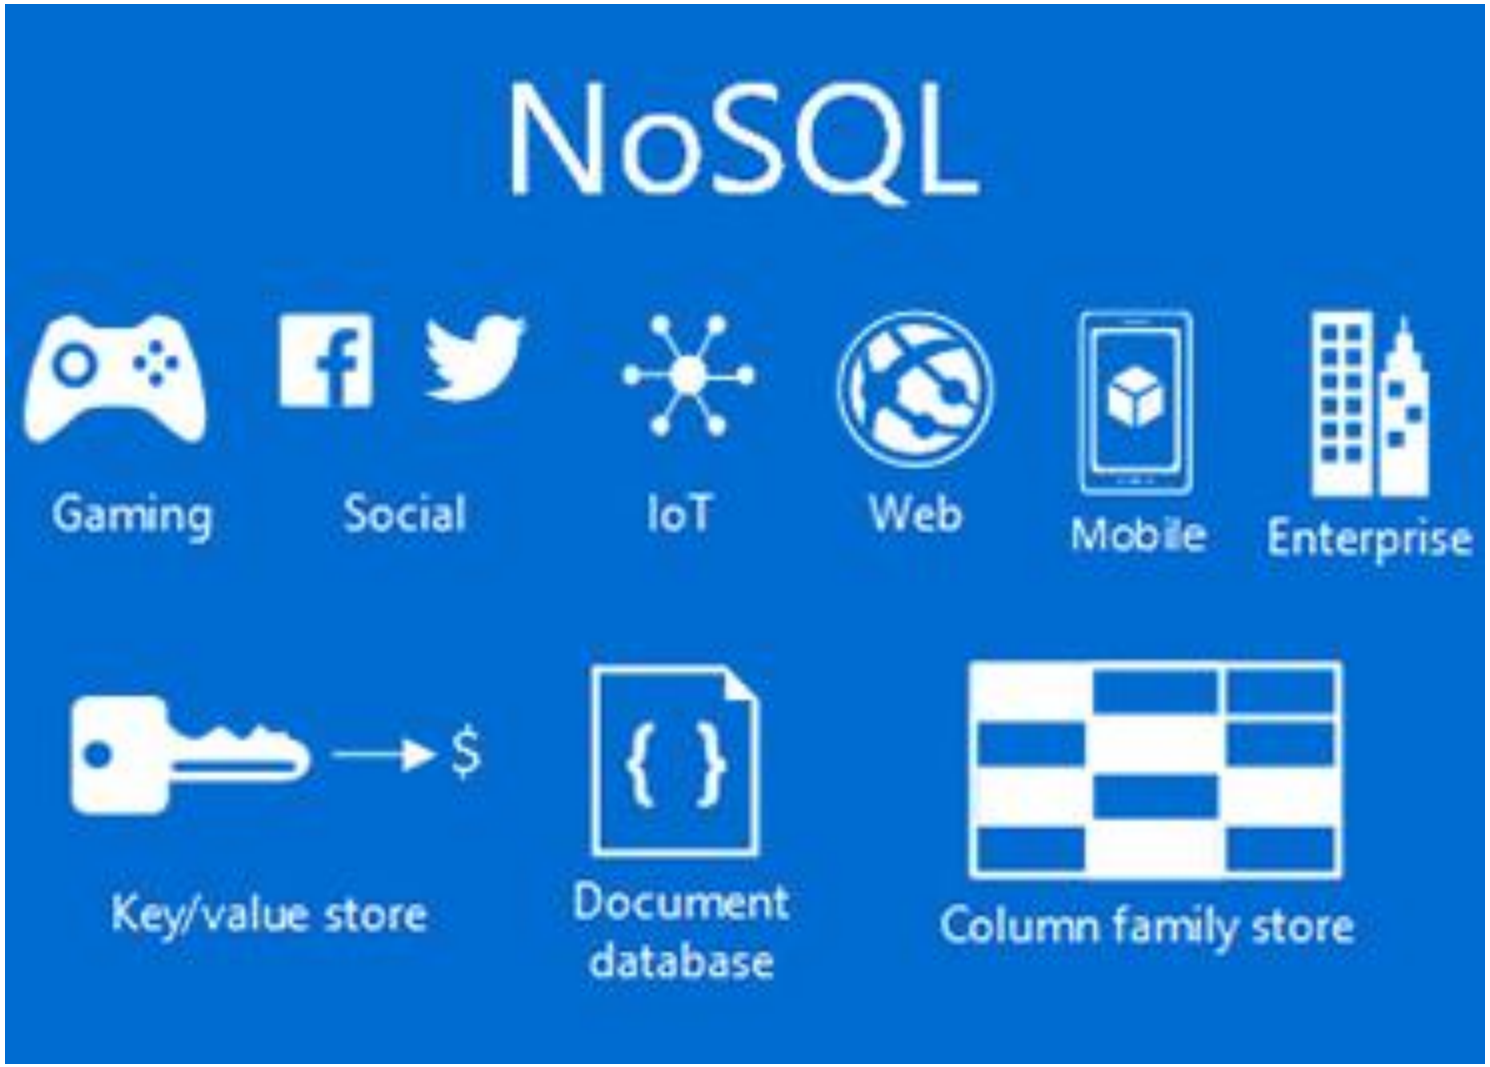

mongoDB

amazon DynamoDB

Elasticsearch

cassandra

redis

APACHE HBASE

빅데이터 프로세싱 솔루션

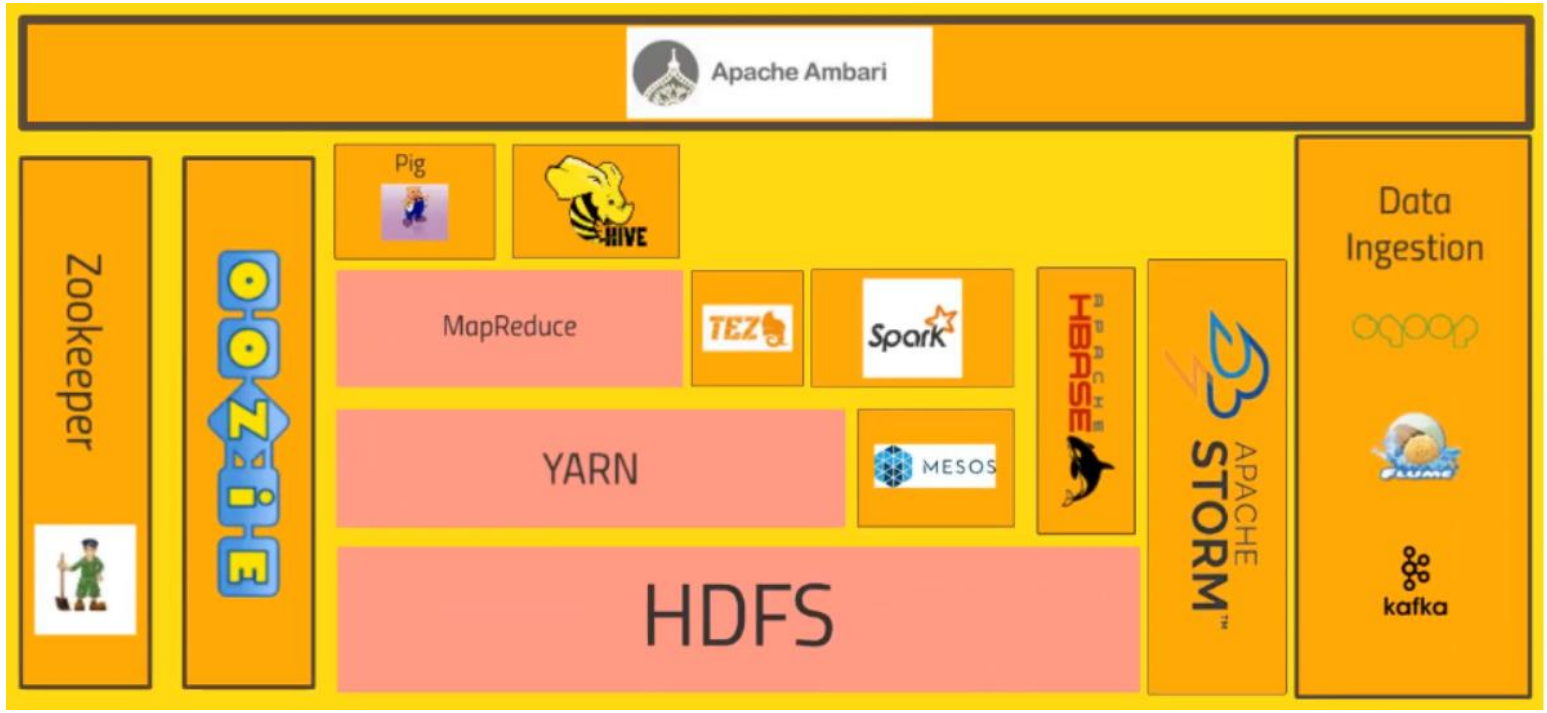

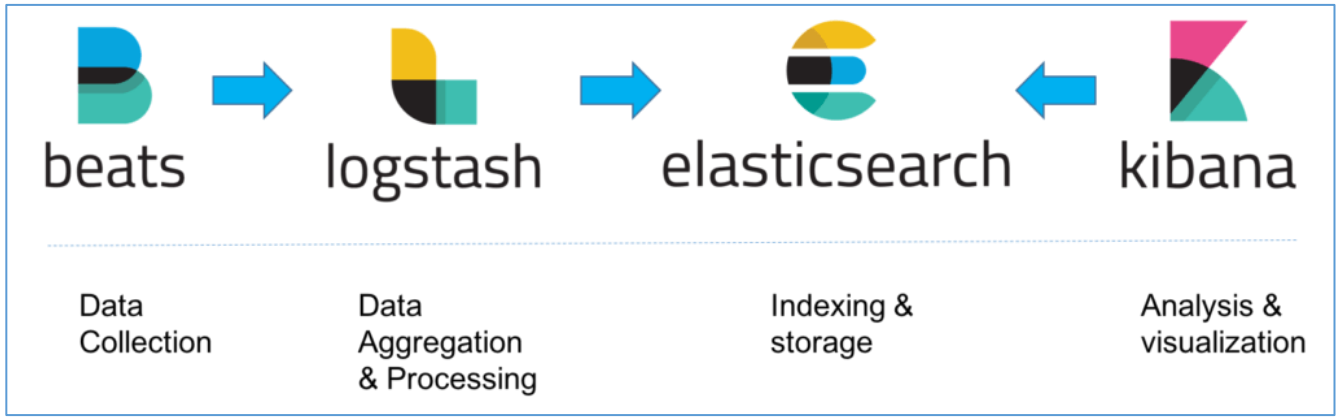

빅데이터 기술

■ 빅데이터 저장기술

- 다양하고 많은 양의 빅데이터를 저장하고 관리하는 기술이 필수
- 대표적인 빅데이터 저장기술 : 하둡(Hadoop), NoSQL(Not Only SQL)
- 하둡(Hadoop) : 대용량 데이터를 분산 처리할 수 있는 자바 기반의 오픈 소스 프레임워크
- NoSQL(Not Only SQL) : 관계형데이터베이스의 일관성 특징보다는 가용성과 확장성에 중점을 둔 데이터베이스

■ 빅데이터 분석기술

- 텍스트 마이닝, 오피니언 마이닝, 소셜 네트워크 분석, 패턴인식, 머신러닝, 딥러닝, 자연어 처리 기술 활용
- 텍스트 마이닝(text mining) : 텍스트 데이터에서 자연어 처리 기술을 기반해 가치 있는 정보를 추출하고 가공
- 오피니언 마이닝(opinion mining) : SNS, 블로그 게시글 등에서 사용자들의 의견을 수집하여 제품과 서비스에 대한 감성을 파악하거나 유용한 정보로 재가공하는 기술
- 소셜 네트워크 분석(social network analysis) : 소셜 네트워크상에서의 영향력인 사람/데이터 등 객체 간의 관계/특성을 분석하고 시각화하는 기법

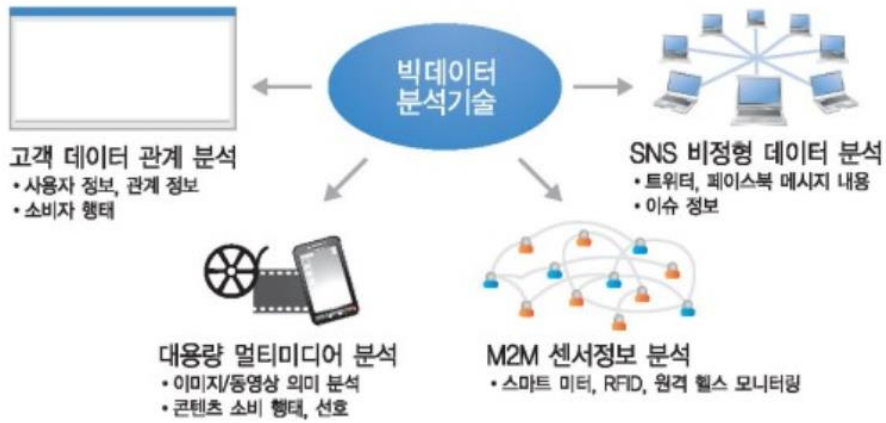

분산시스템

- 로컬 프로세스는 단일 시스템의 컴퓨팅 리소스를(예: 32GB) 사용합니다.
- 더 큰 데이터셋은 SQL 데이터베이스를 사용하여 스토리지를 사용하거나,
  여러대의 컴퓨터로 구성된 분산시스템을 사용해야 합니다.

- 분산 프로세스는 네트워크를 통해 연결된 여러 머신의 컴퓨팅 리소스를 액세스 할 수 있습니다.
- 단일 머신을 Scale Up 하는 것보다 여러대의 머신으로 확장(Scale Out)하는 것이 더 쉽습니다.
- 분산시스템에서는 한 대의 시스템에 장애가 발생해도 전체 네트워크가 계속 작동 할 수 있습니다.

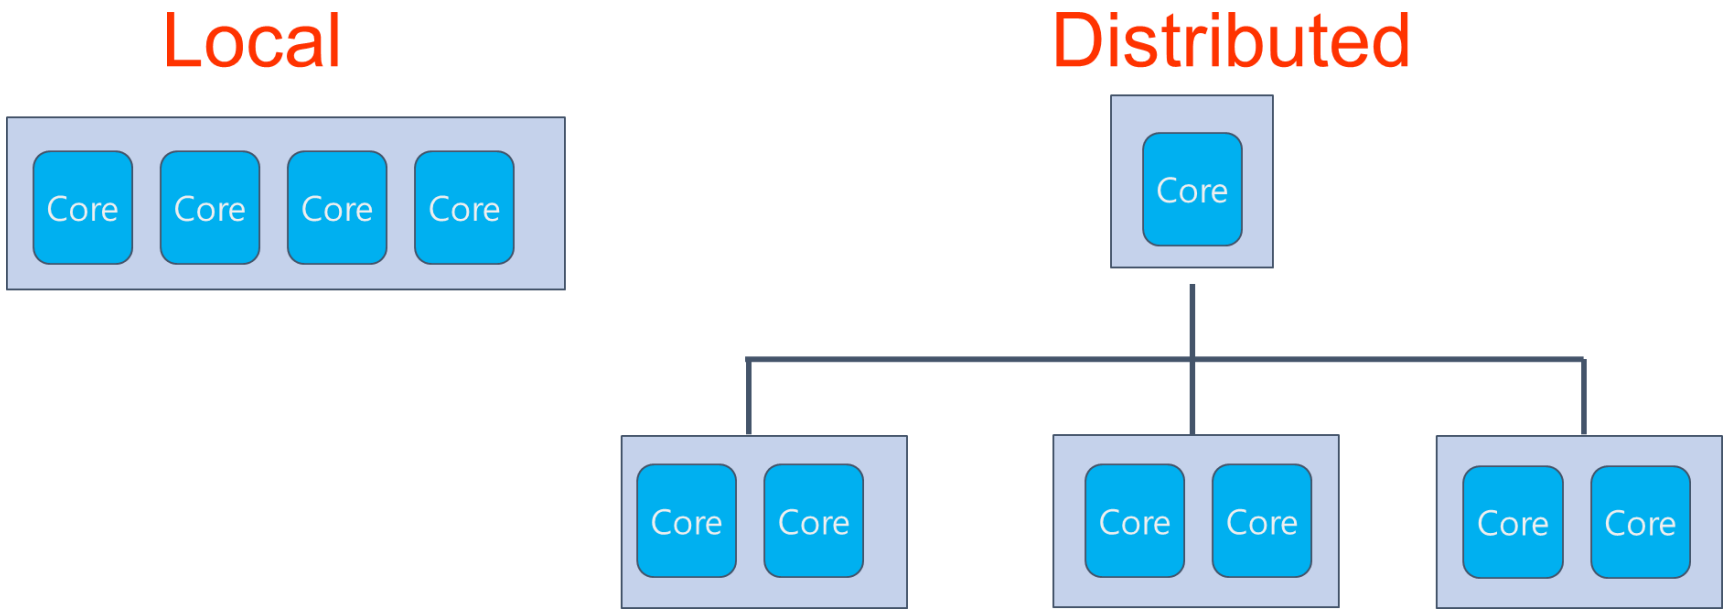

하둡(Hadoop)

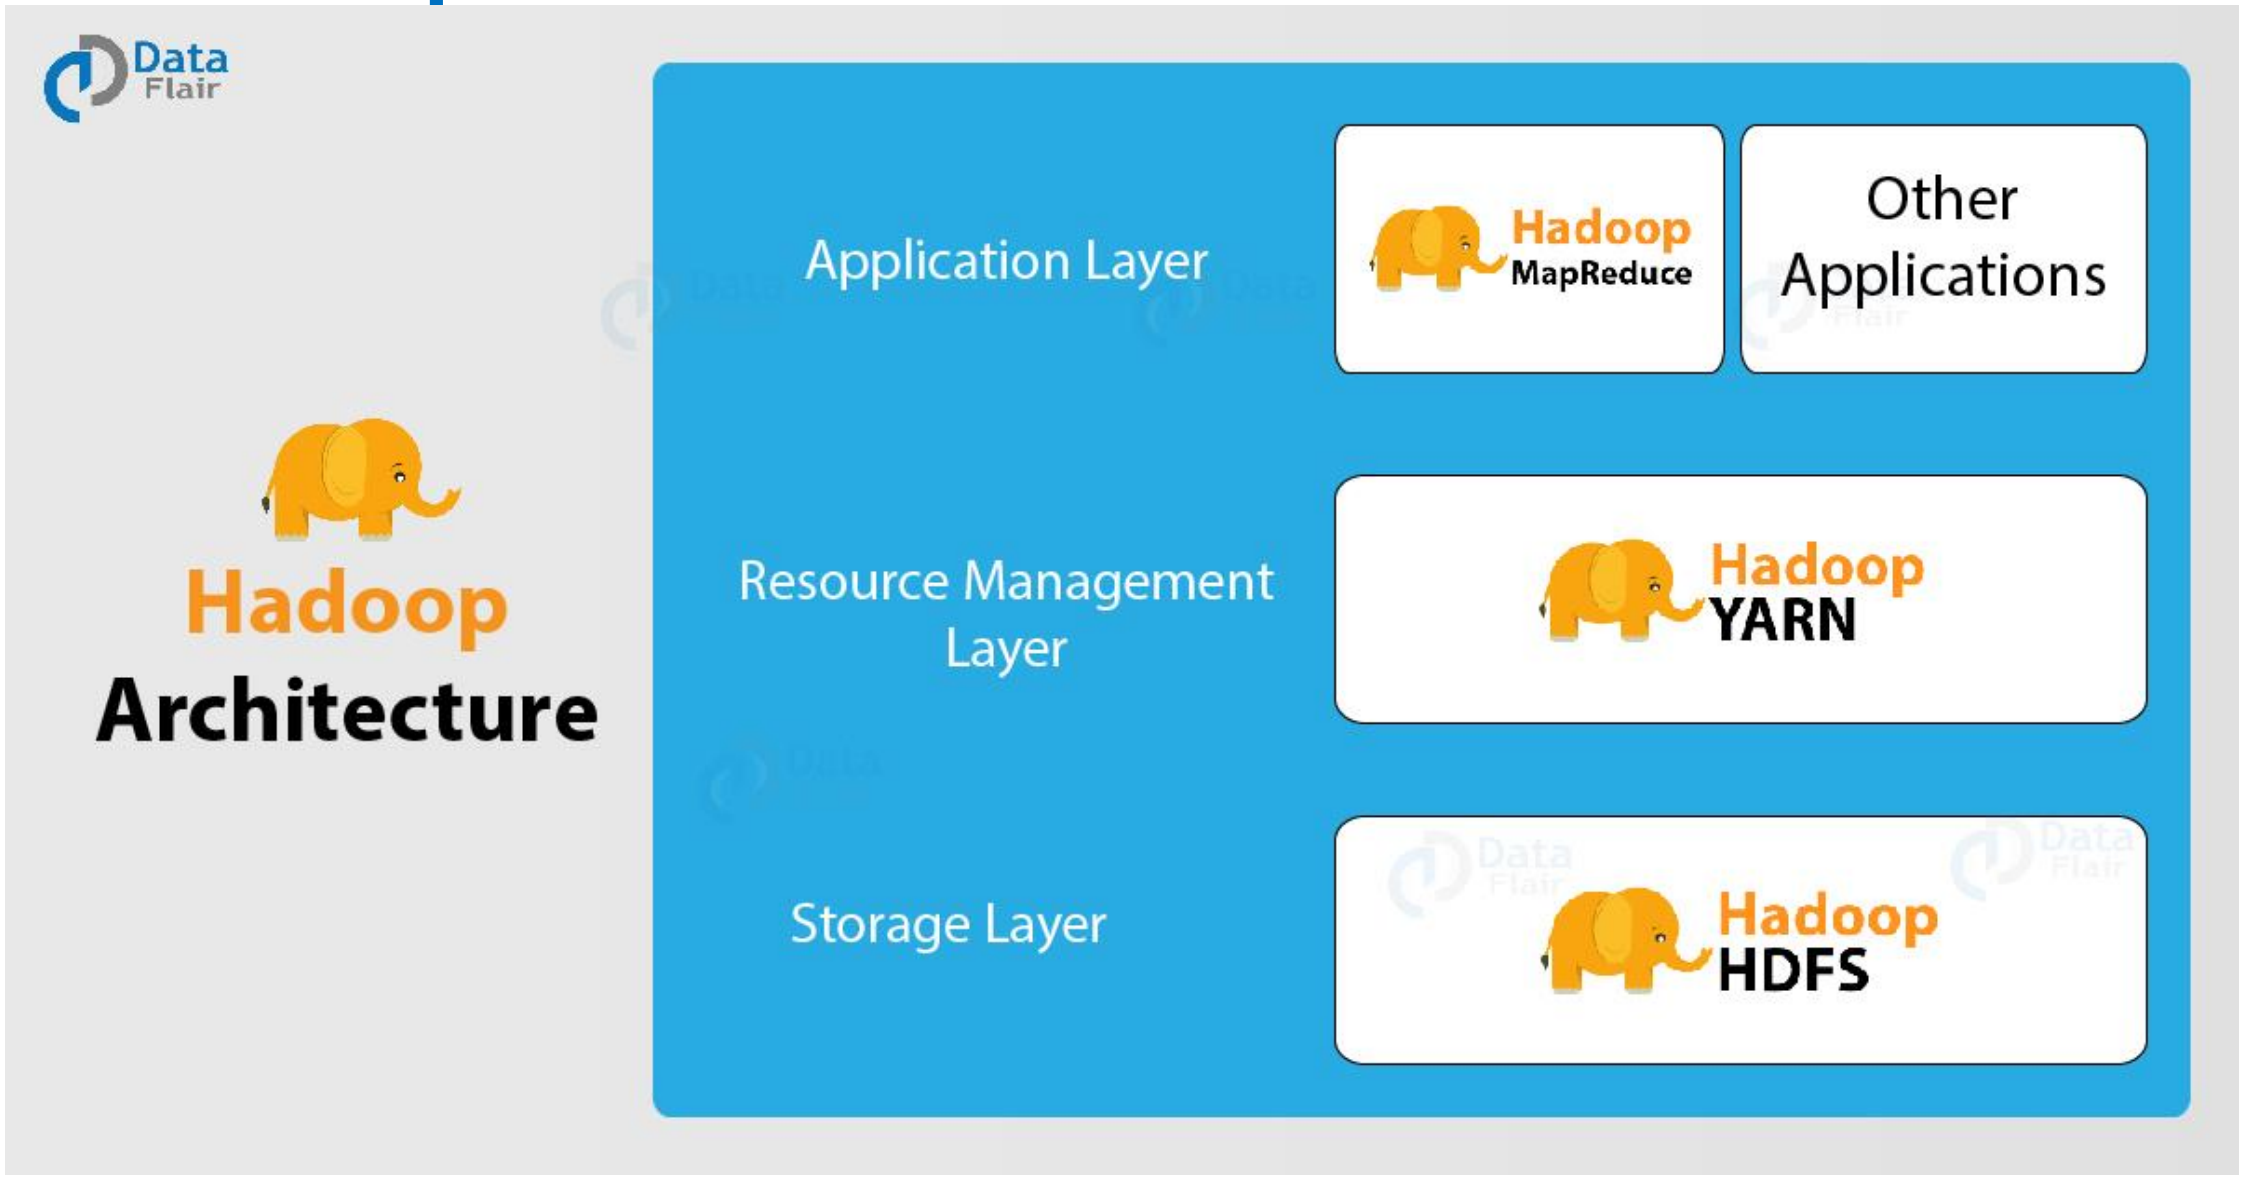

https://data-flair.training/blogs/hadoop-architecture/

하둡 HDFS(Hadoop Distributed File System)

- HDFS는 파일을 분산 저장하기 위해서 먼저 파일의 메타 데이터와 컨텐츠 데이터를 분리합니다.
- 메타 데이터 : 파일의 접근 권한, 생성일, 수정일, 네임 스페이스 등 파일에 대해 설명하는 정보
- 컨텐츠 데이터 : 실제 파일에 저장된 데이터
- 파일의 메타데이터는 네임 노드에 저장되며 컨텐츠 데이터는 블록 단위로 쪼개져서 데이터 노드에 저장 됩니다.

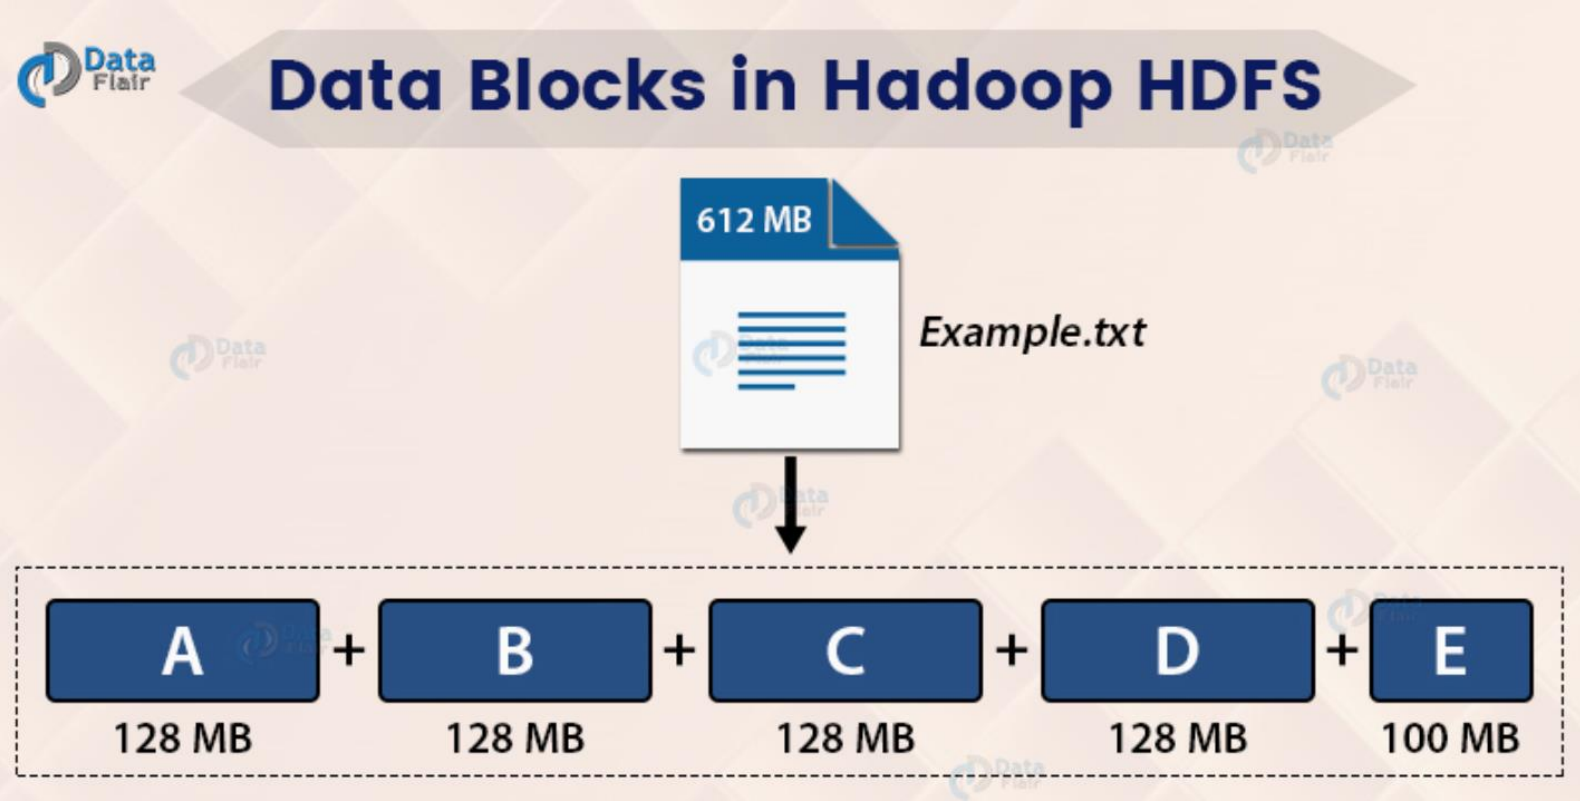

https://yeomko.tistory.com/38

하둡 HDFS 데이터 노드

- 파일의 컨텐츠 데이터는 블록 단위로 나뉘며, 블록의 기본 크기는 128MB이며 최소 3개의 복사본을 생성하여 분산 저장합니다.
- 데이터 노드는 그 중 하나의 복사본을 저장하는 것입니다.

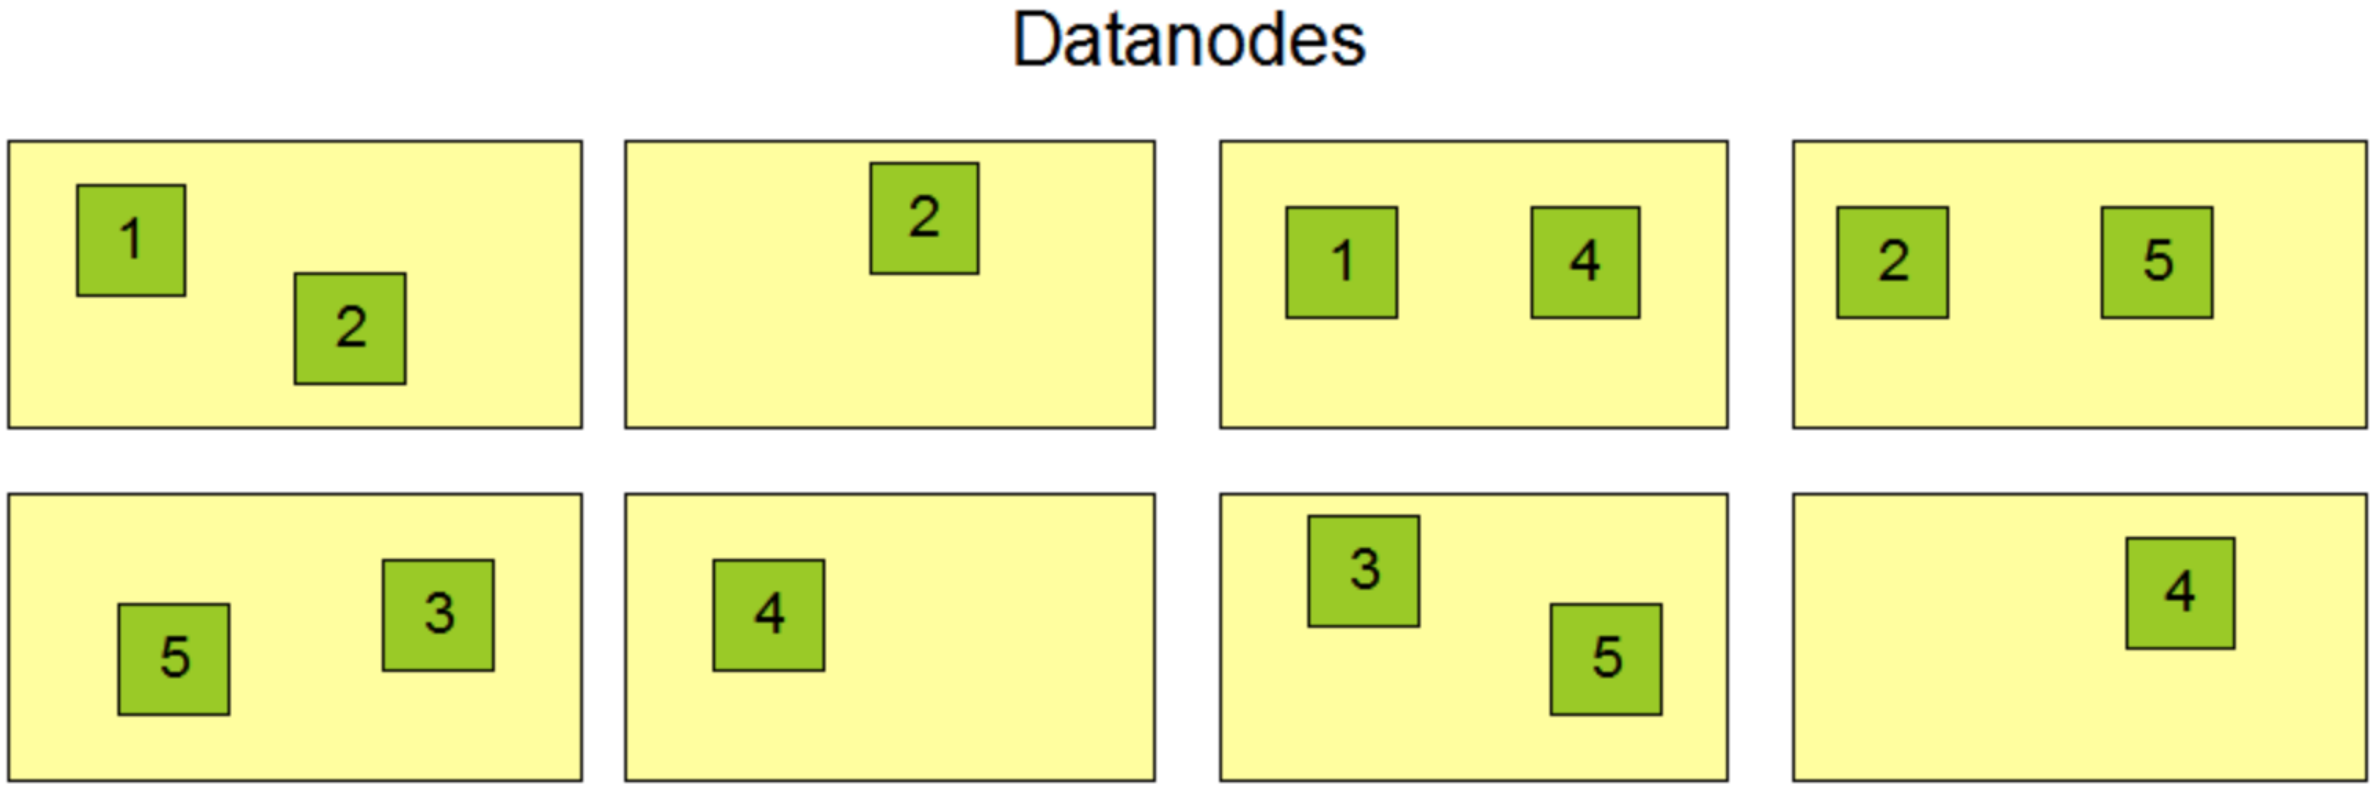

https://yeomko.tistory.com/38

하둡 에코시스템

■ 하둡 에코시스템

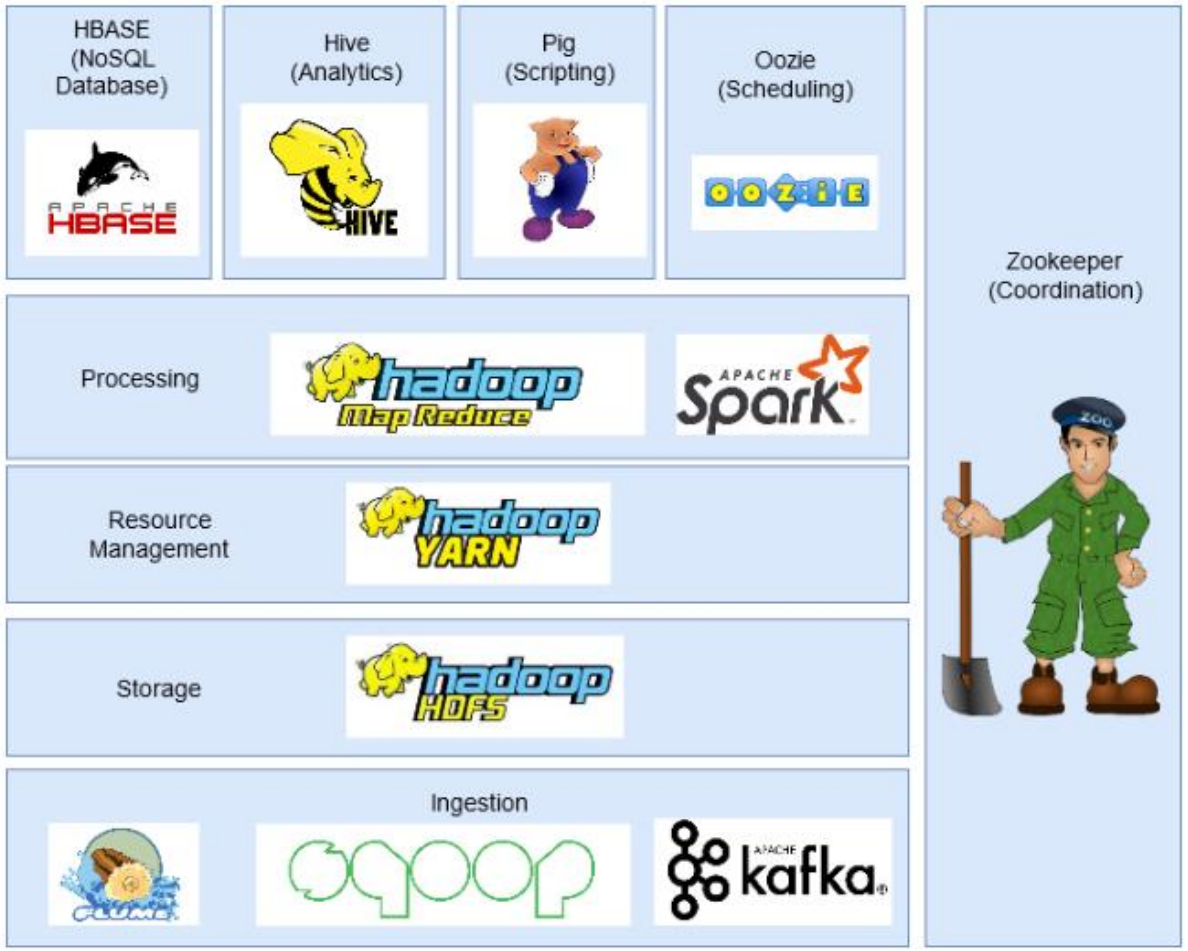

■ MapReduce 알고리즘

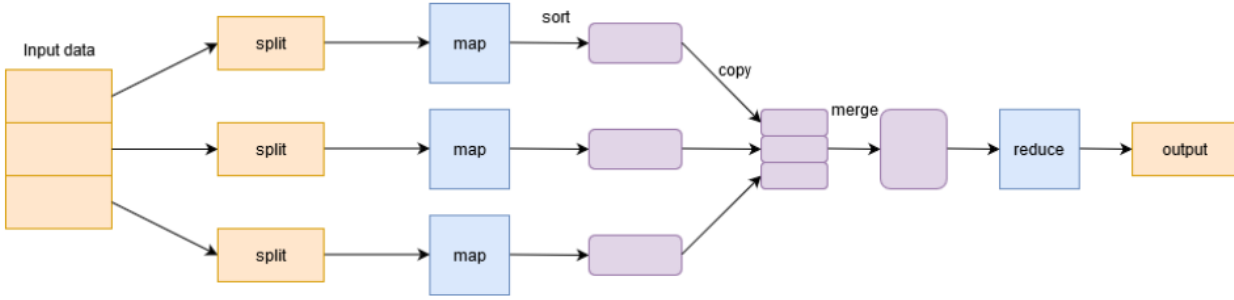

■ 빅데이터 프로세싱 단계

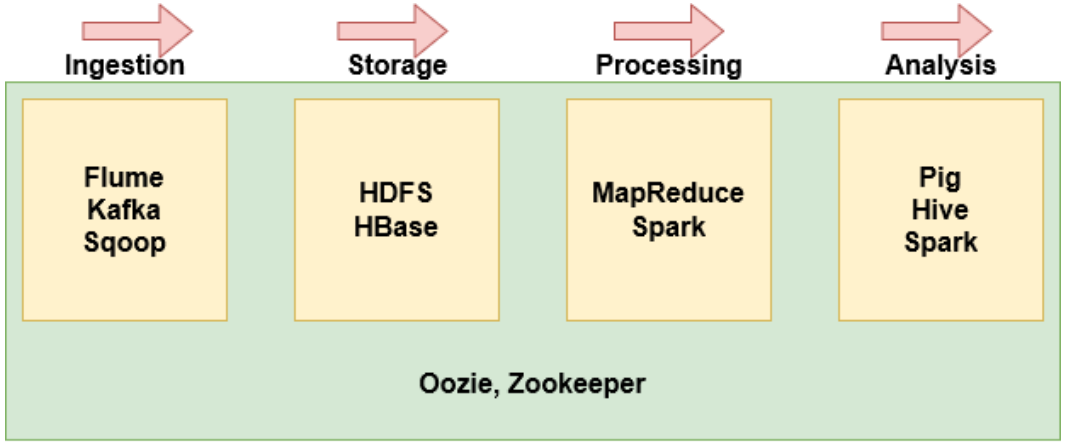

https://www.analyticsvidhya.com/blog/2020/10/introduction-hadoop-ecosystem/

HDP(Hortonworks Data Platform)

https://www.cloudera.com/downloads/hortonworks-sandbox.html

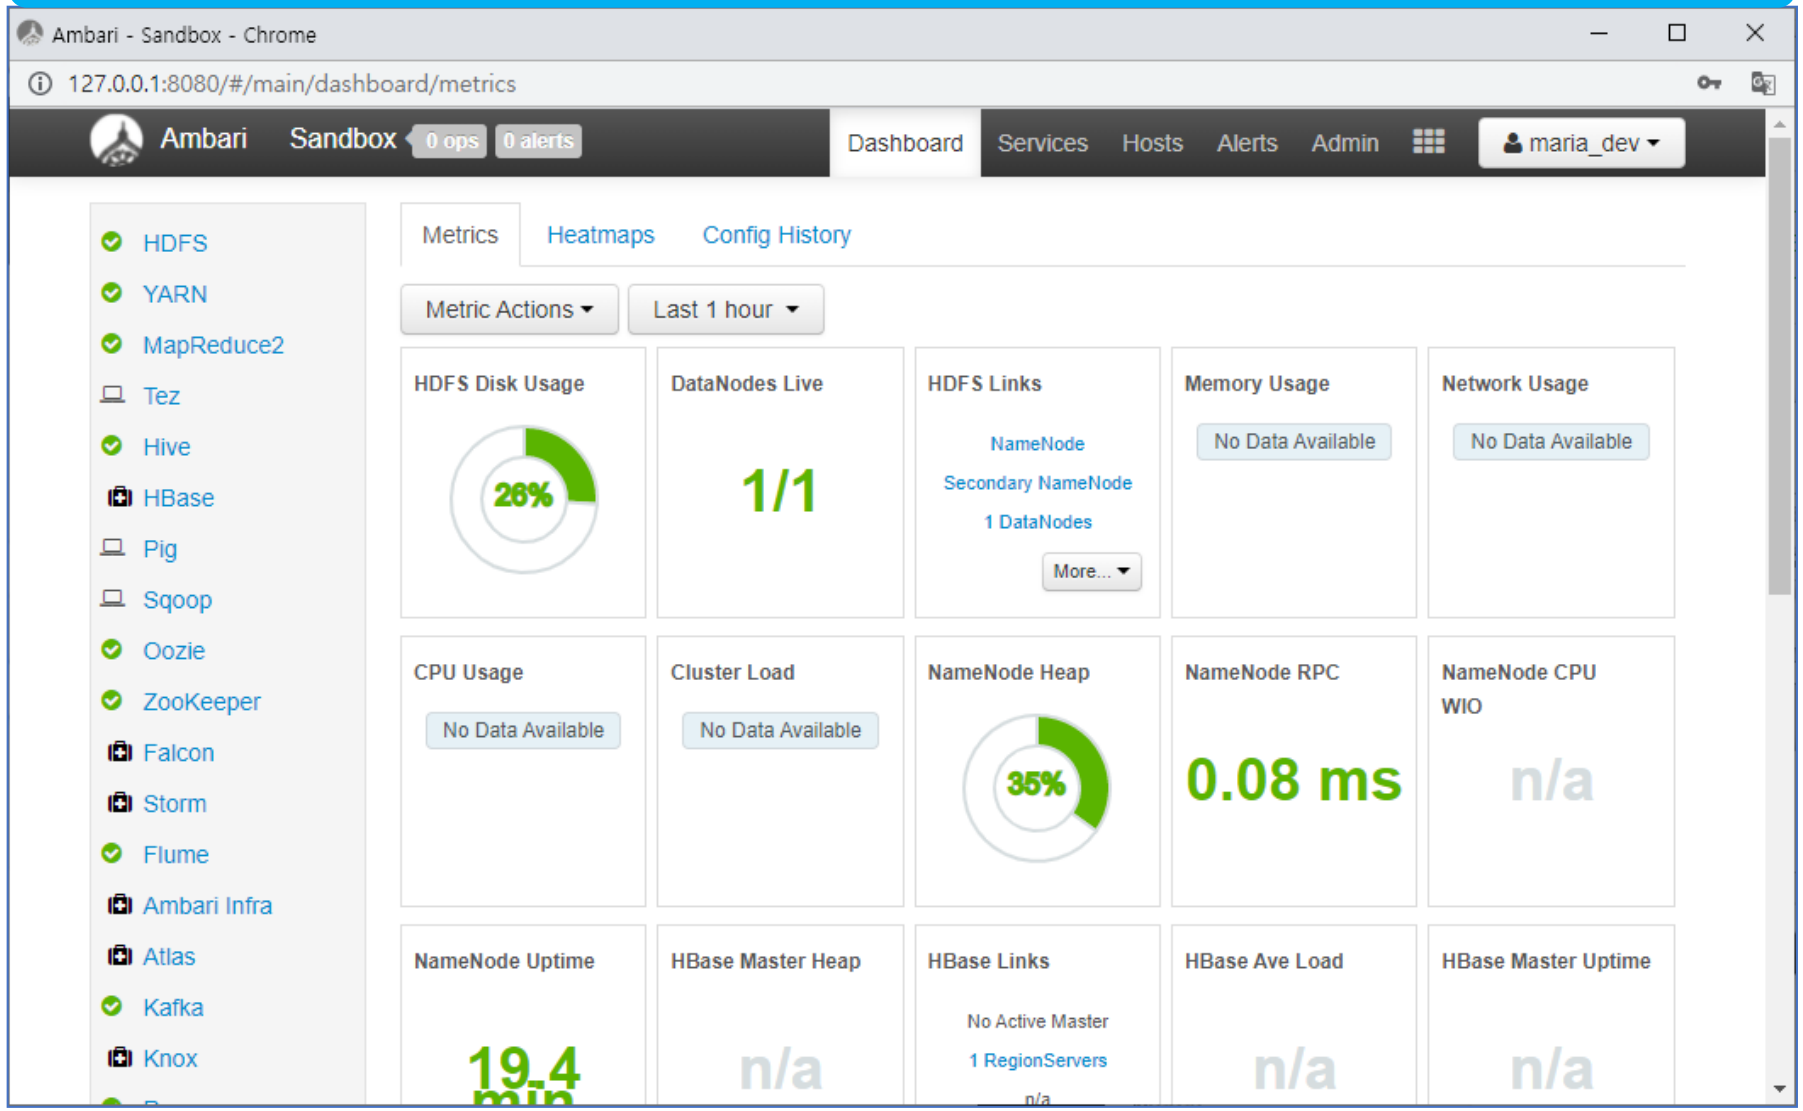

빅데이터 분산 프로세싱 엔진 스파크(Spark)

- ✓ A fast and general engine for large-scale data processing
- ✓ It's scalable
- ✓ It's fast
- ✓ It's hot
- ✓ It's not that hard
- ✓ Code in Python, Java, or Scala

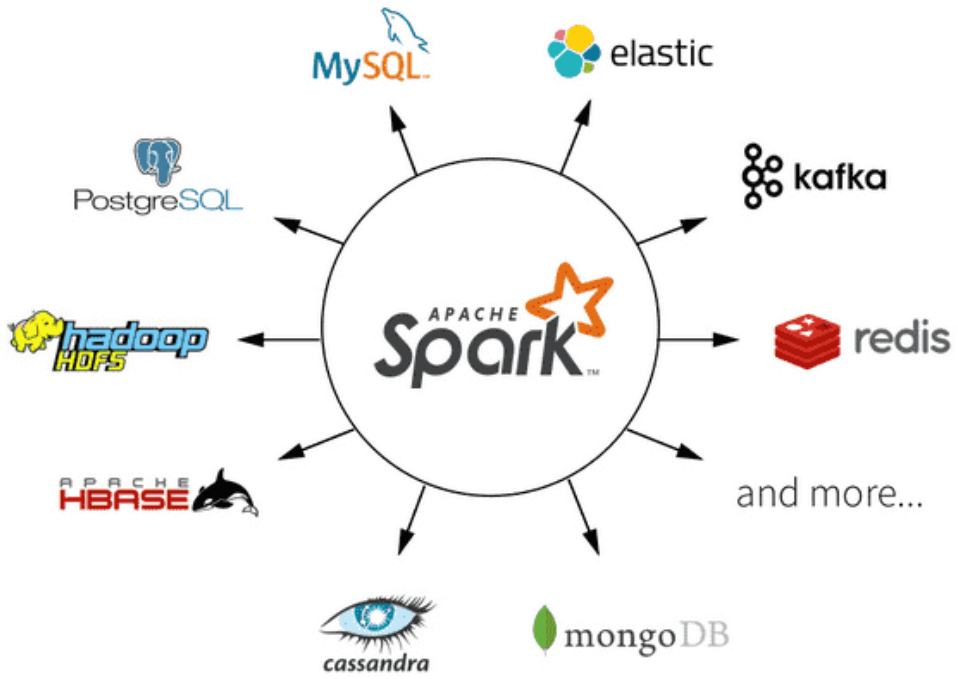

스파크의 구조

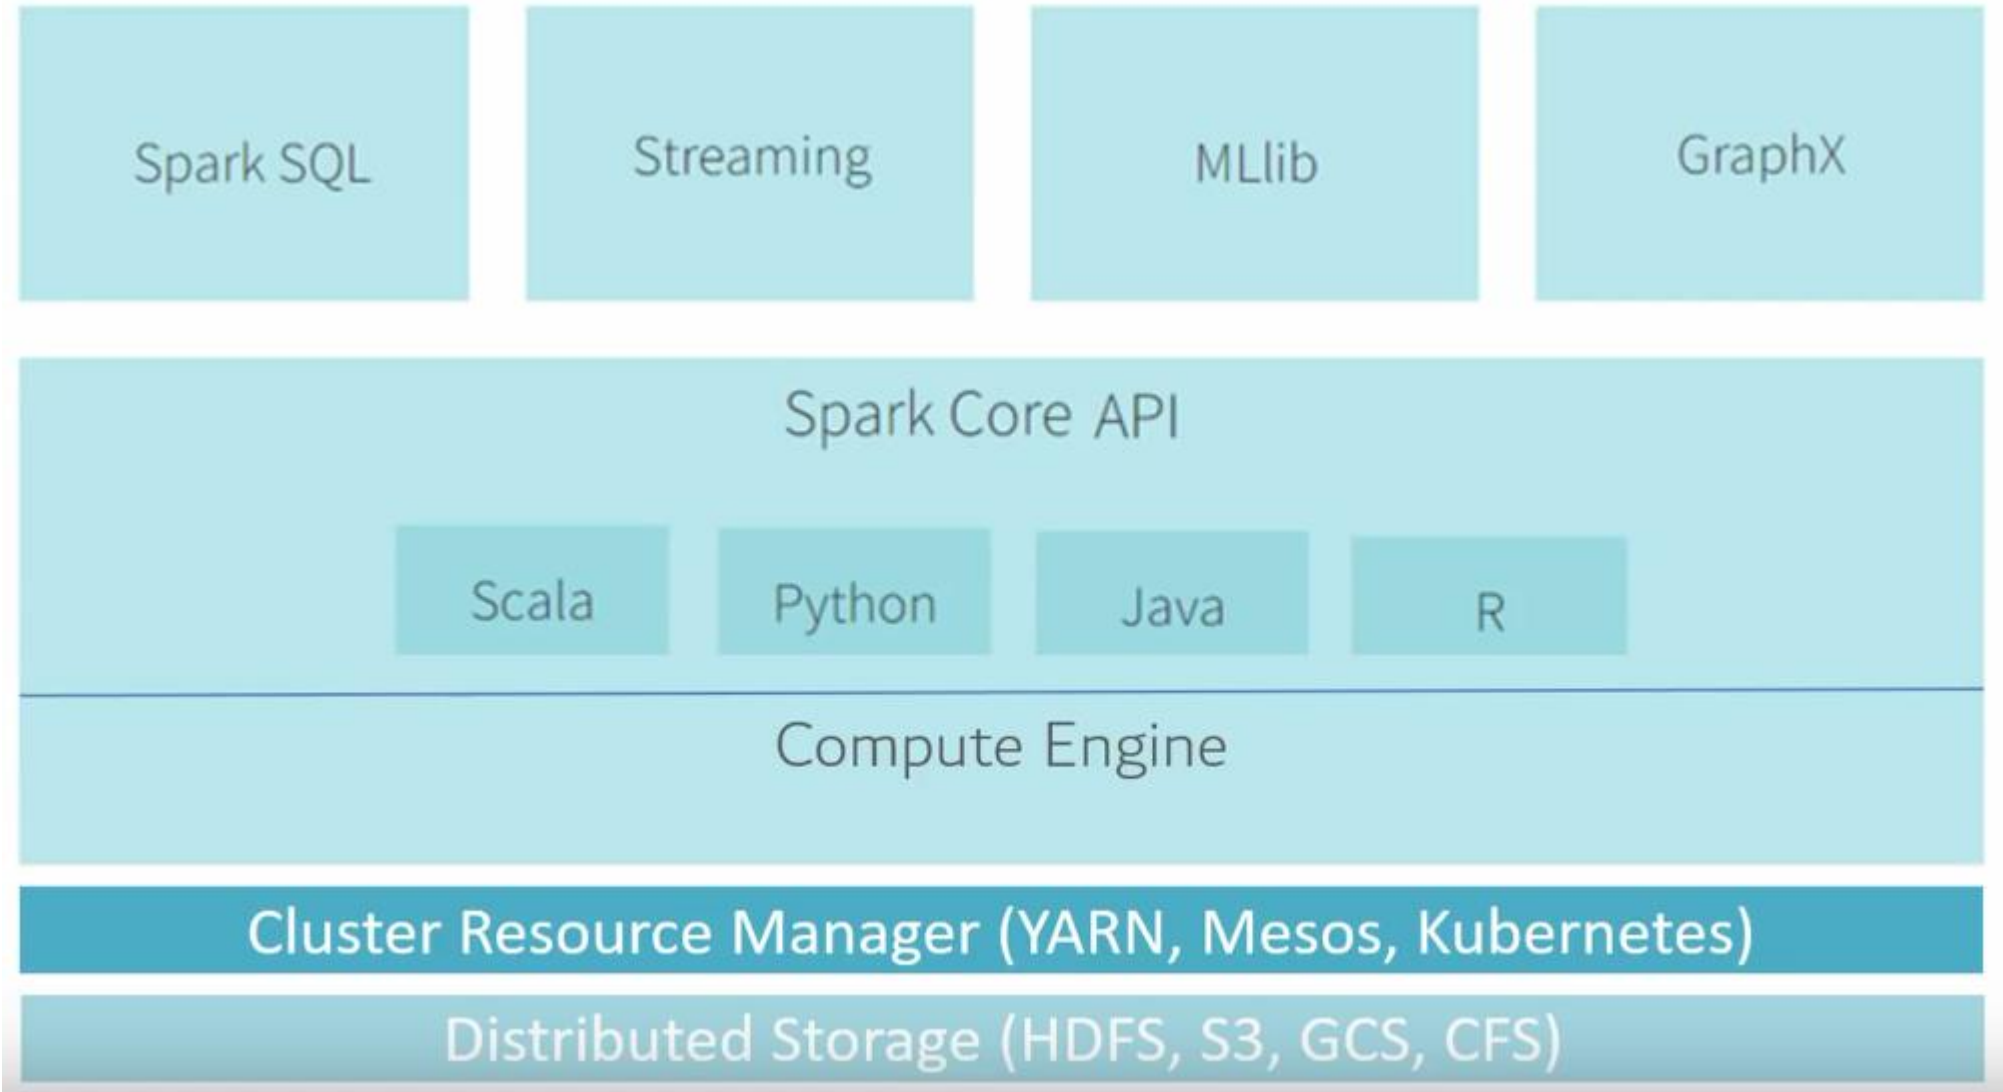
Spark SQL
Streaming
MLlib
GraphX
Spark Core API
Scala
Python
Java
R
Compute Engine
Cluster Resource Manager (YARN, Mesos, Kubernetes)
Distributed Storage (HDFS, S3, GCS, CFS)

Colab에서 PySpark 사용하는 방법

spark_in_colab.ipynb

Colab에서 PySpark 사용하는 방법

findspark 라이브러리 설치

```
[ ]  !pip install -q findspark
```

환경변수 설정

```
[ ]  import os
     os.environ["JAVA_HOME"] = "/usr/lib/jvm/java-8-openjdk-amd64"
     os.environ["SPARK_HOME"] = "/content/spark-3.1.2-bin-hadoop2.7"
```

테스트

```
[ ]  import findspark
     findspark.init()
```

```
[ ]  findspark.find()
```

```
'/content/spark-3.1.2-bin-hadoop2.7'
```

PySpark DataFrame 실습

spark_dataframe.ipynb

■ 데이터 파일 : people.json

{"name":"Michael"}

{"name":"Andy", "age":30}

{"name":"Justin", "age":19}

■ Creating a DataFrame

```
[2]  from pyspark.sql import SparkSession
```

```
[3]  # May take a little while on a local computer
     spark = SparkSession.builder.appName("Basics").getOrCreate()
```

```
[4]  df = spark.read.json('people.json')
```

PySpark DataFrame 실습

■ Showing the data

```
[5]  # Note how data is missing!
     df.show()
```

```
+----+-------+
| age|   name|
+----+-------+
|null|Michael|
|  30|   Andy|
|  19| Justin|
+----+-------+
```

```
[6]  df.printSchema()
```

```
root
 |-- age: long (nullable = true)
 |-- name: string (nullable = true)
```

```
[7]  df.columns
```

```
['age', 'name']
```

```
[8]  df.describe()
```

```
DataFrame[summary: string, age: string, name: string]
```

PySpark DataFrame 실습

■ Infer schema

```
[9]  from pyspark.sql.types import StructField,StringType,IntegerType,StructType
```

```
[10] data_schema = [StructField("age", IntegerType(), True),StructField("name", StringType(), True)]
```

```
[11] final_struc = StructType(fields=data_schema)
```

```
[12] df = spark.read.json('people.json', schema=final_struc)
```

```
[13] df.printSchema()
```

```
root
 |-- age: integer (nullable = true)
 |-- name: string (nullable = true)
```

PySpark DataFrame 실습

■ Grabbing the data

```
[14]  df['age']
```

```
Column<'age'>
```

```
[15]  type(df['age'])
```

```
pyspark.sql.column.Column
```

```
[16]  df.select('age')
```

```
DataFrame[age: int]
```

```
[17]  type(df.select('age'))
```

```
pyspark.sql.dataframe.DataFrame
```

```
[18]  df.select('age').show()
```

```
+----+
| age|
+----+
|null|
|  30|
|  19|
+----+
```

PySpark DataFrame 실습

■ Multiple Columns

```
[20]  df.select(['age','name'])
```

```
DataFrame[age: int, name: string]
```

```
[21]  df.select(['age','name']).show()
```

```
+----+-------+
| age|   name|
+----+-------+
|null|Michael|
|  30|   Andy|
|  19| Justin|
+----+-------+
```

■ Creating new columns

```
[22]  # Adding a new column with a simple copy
      df.withColumn('newage',df['age']).show()
```

```
+----+-------+------+
| age|   name|newage|
+----+-------+------+
|null|Michael|  null|
|  30|   Andy|    30|
|  19| Justin|    19|
+----+-------+------+
```

PySpark DataFrame 실습

■ More complicated operations to create new columns

```
[25]  df.withColumn('doubleage',df['age']*2).show()
```

```
+----+-------+---------+
| age|   name|doubleage|
+----+-------+---------+
|null|Michael|     null|
|  30|   Andy|       60|
|  19| Justin|       38|
+----+-------+---------+
```

```
[26]  df.withColumn('add_one_age',df['age']+1).show()
```

```
+----+-------+-----------+
| age|   name|add_one_age|
+----+-------+-----------+
|null|Michael|       null|
|  30|   Andy|         31|
|  19| Justin|         20|
+----+-------+-----------+
```

■ PySpark 튜토리얼

https://sparkbyexamples.com/pyspark-tutorial/

데이터 웨어하우스(DW)의 한계

■ 데이터 웨어하우스의 한계

- SaaS 활용이 폭발적으로 증가하면서 수집 데이터의 다양성과 종류가 크게 증가(비정형, 반정형 데이터, 실시간 스트리밍)
- SaaS API에 사용되는 반정형 데이터(JSON , Avro, Protocol Buffer)를 처리하지 못함
- 비정형 데이터(binary, image, video, audio data)를 처리하지 못함
- 구조화된 데이터의 빈번한 스키마 변경에 대응이 어려움
- 데이터웨어하우스에 제공하는 SQL엔진과 저장 프로시저만 사용해야 하는 제약이 있음
- 스토리지와 처리영역이 결합되어 있어 확장성과 유연성에 제약이 큼
- 배치 중심 처리 방식으로 스트림 데이터가 처리가 어려움

데이터 웨어하우스(DW)

■ 데이터 레이크

- 방대한 양의 원시 데이터를 보관하는 storage repository로,
  특정 주제나 목적 중심이 아닌 통합되지 않은 데이터 집합
- 과거 10년 동안 Hadoop이 데이터 레이크에 대한 실질적인 표준이었음

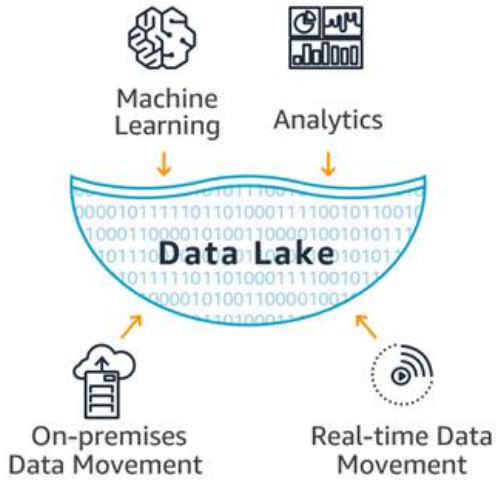

■ Hadoop의 단점

- 매우 복잡한 시스템
- 비즈니스 사용자가 비정형 형태를 이해하고 활용하기에 쉽지 않은 시스템
- 개발자도 잘 사용하려면 많은 노력이 필요
- 스토리지와 컴퓨팅이 분리되어 있지 않음
- 시스템 확장을 위한 하드웨어 추가/변경에 수개월이 소요될 수 있음

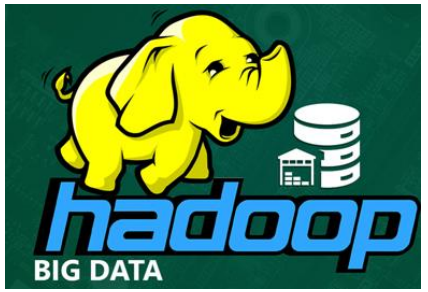

퍼블릭 클라우드 활용

하둡의 장점은 살리고 단점들을 보완해서 유연성을 훨씬 더 가져다 주는 솔루션이 클라우드와 함께 등장함

- 온디맨드 스토리지, 컴퓨팅 리소스 프로비저닝, 사용량 기반 요금 지불 모델을 갖춘 퍼블릭 클라우드의 등장으로 데이터 레이크 설계가 Hadoop의 한계를 뛰어 넘음
- 퍼블릭 클라우드를 통해 데이터 레이크는 설계 및 확장성 측면에서 더 많은 유연성을 포함하고 필요한 지원(support)의 양을 대폭 줄이는 동시에 비용 효율성을 높임
- 퍼블릭 클라우드의 출현은 분석 데이터 시스템에 관한 모든 것을 바꾸어 놓음
- AWS EMR은 관리형 서비스로 제공되며 AWS에서 Hadoop 및 Spark 작업을 실행할 수 있음

Elastic resources

Modularity(Storage and compute are separate)

Cloud turns CAPEX into OPEX

Pay per use

Managed services are the norm

Instant availability

A new generation of cloud-only processing frameworks

Faster feature introduction

퍼블릭 클라우드 활용 – AWS(Amazon Web Services)

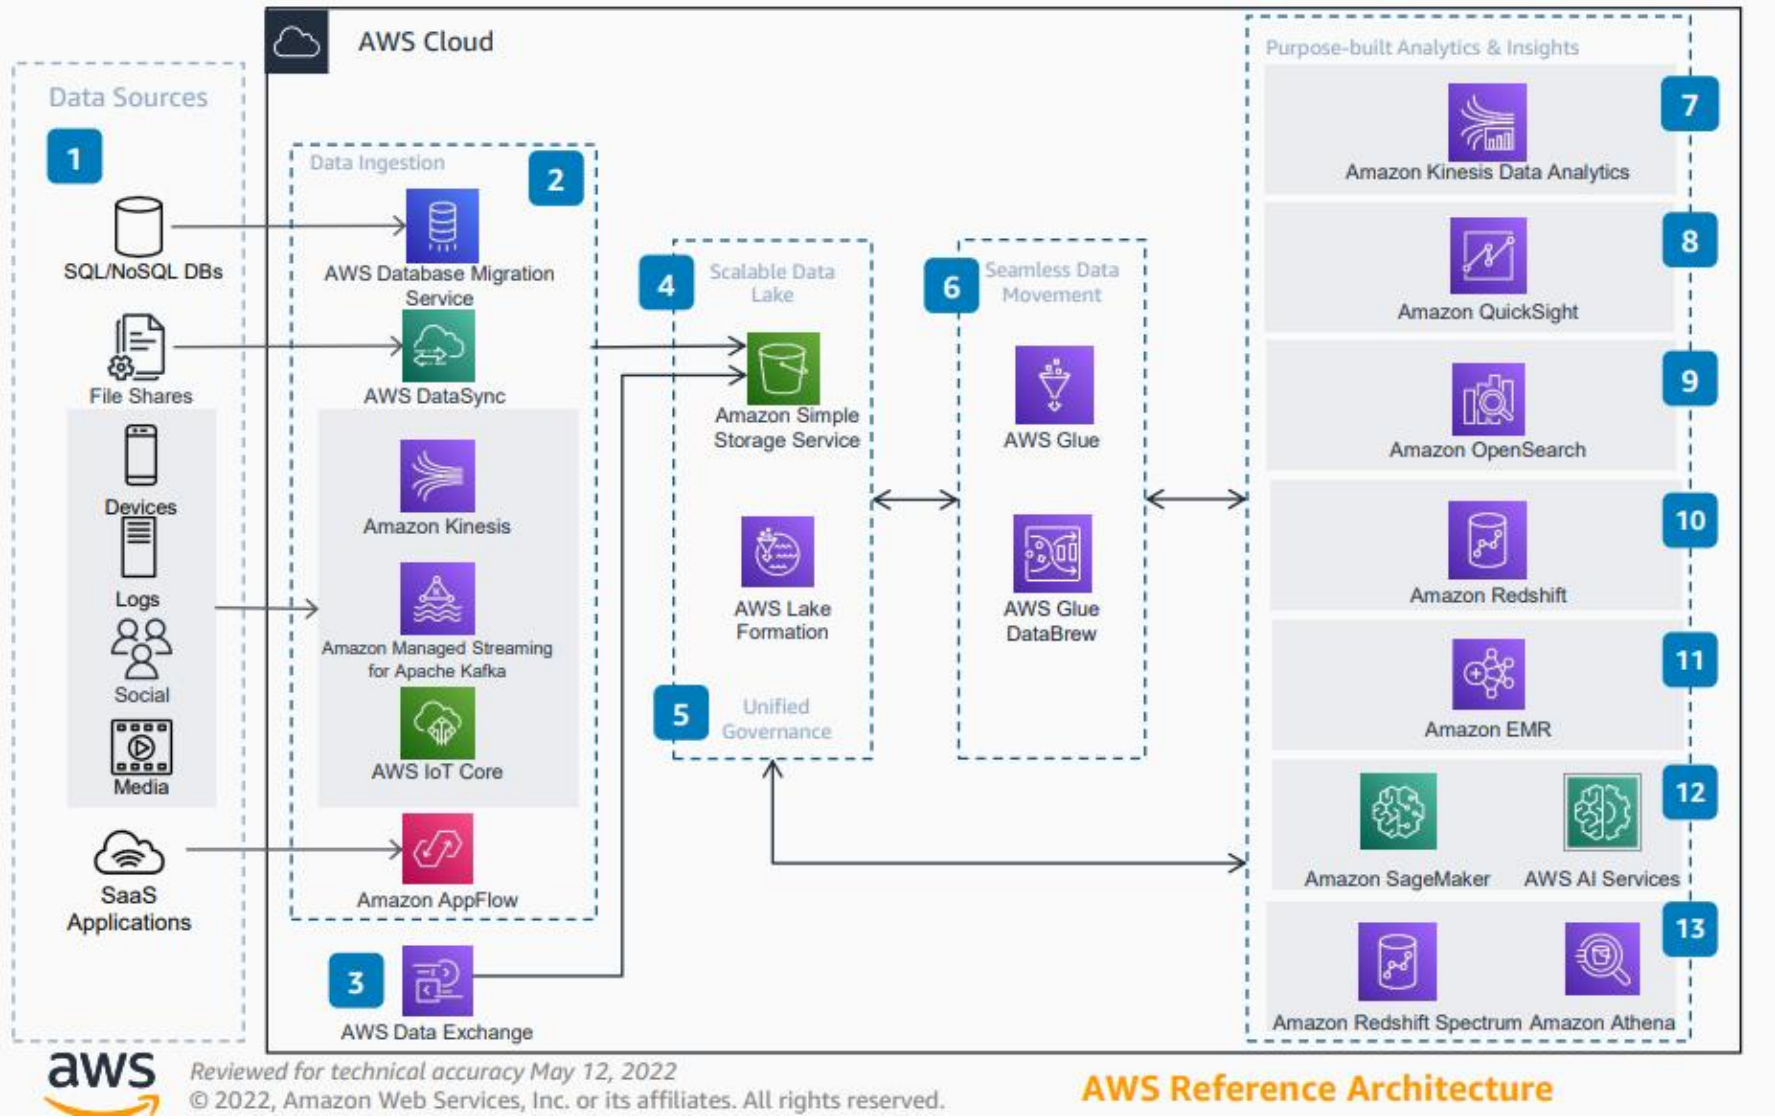

https://d1.awsstatic.com/architecture-diagrams/ArchitectureDiagrams/modern-data-analytics-using-lake-house-ra.pdf?anld_da6

퍼블릭 클라우드 활용 – Microsoft Azure

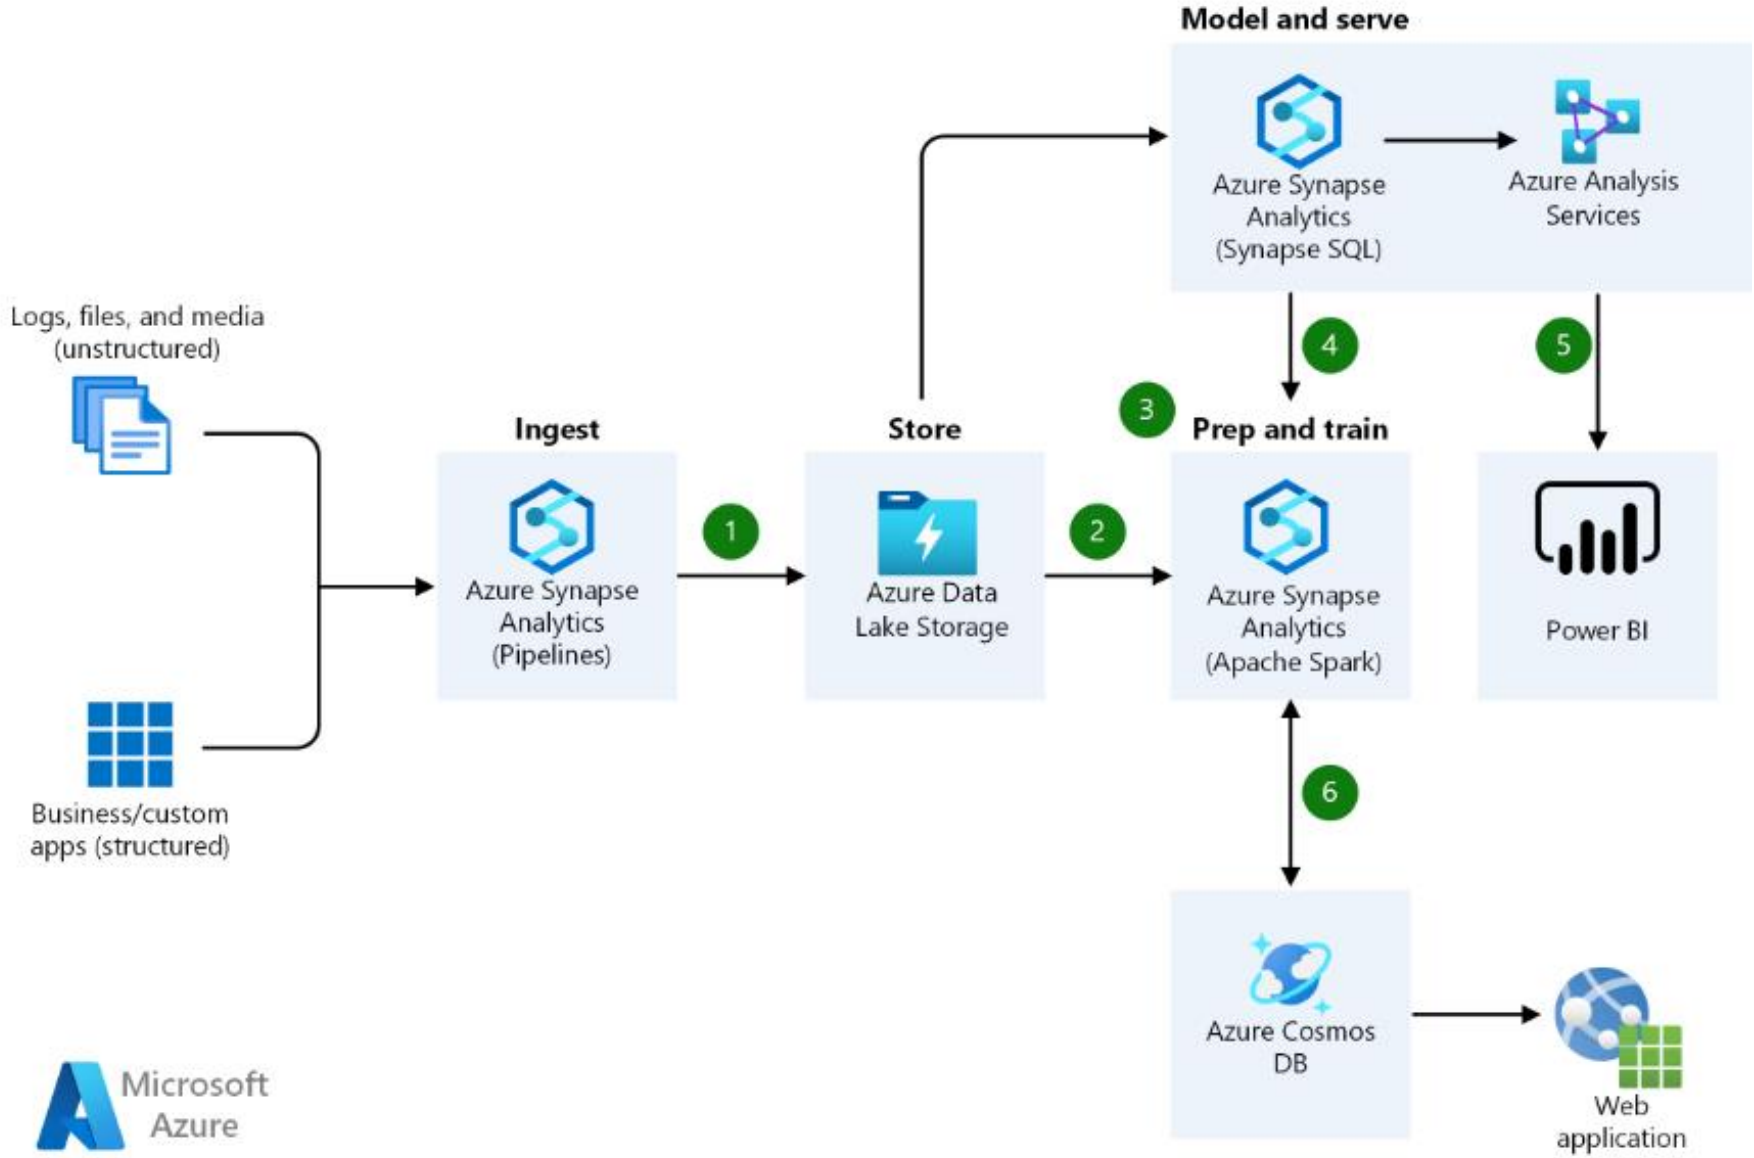

https://learn.microsoft.com/en-us/azure/architecture/solution-ideas/articles/advanced-analytics-on-big-data

퍼블릭 클라우드 활용 – GCP(Google Cloud Platform)

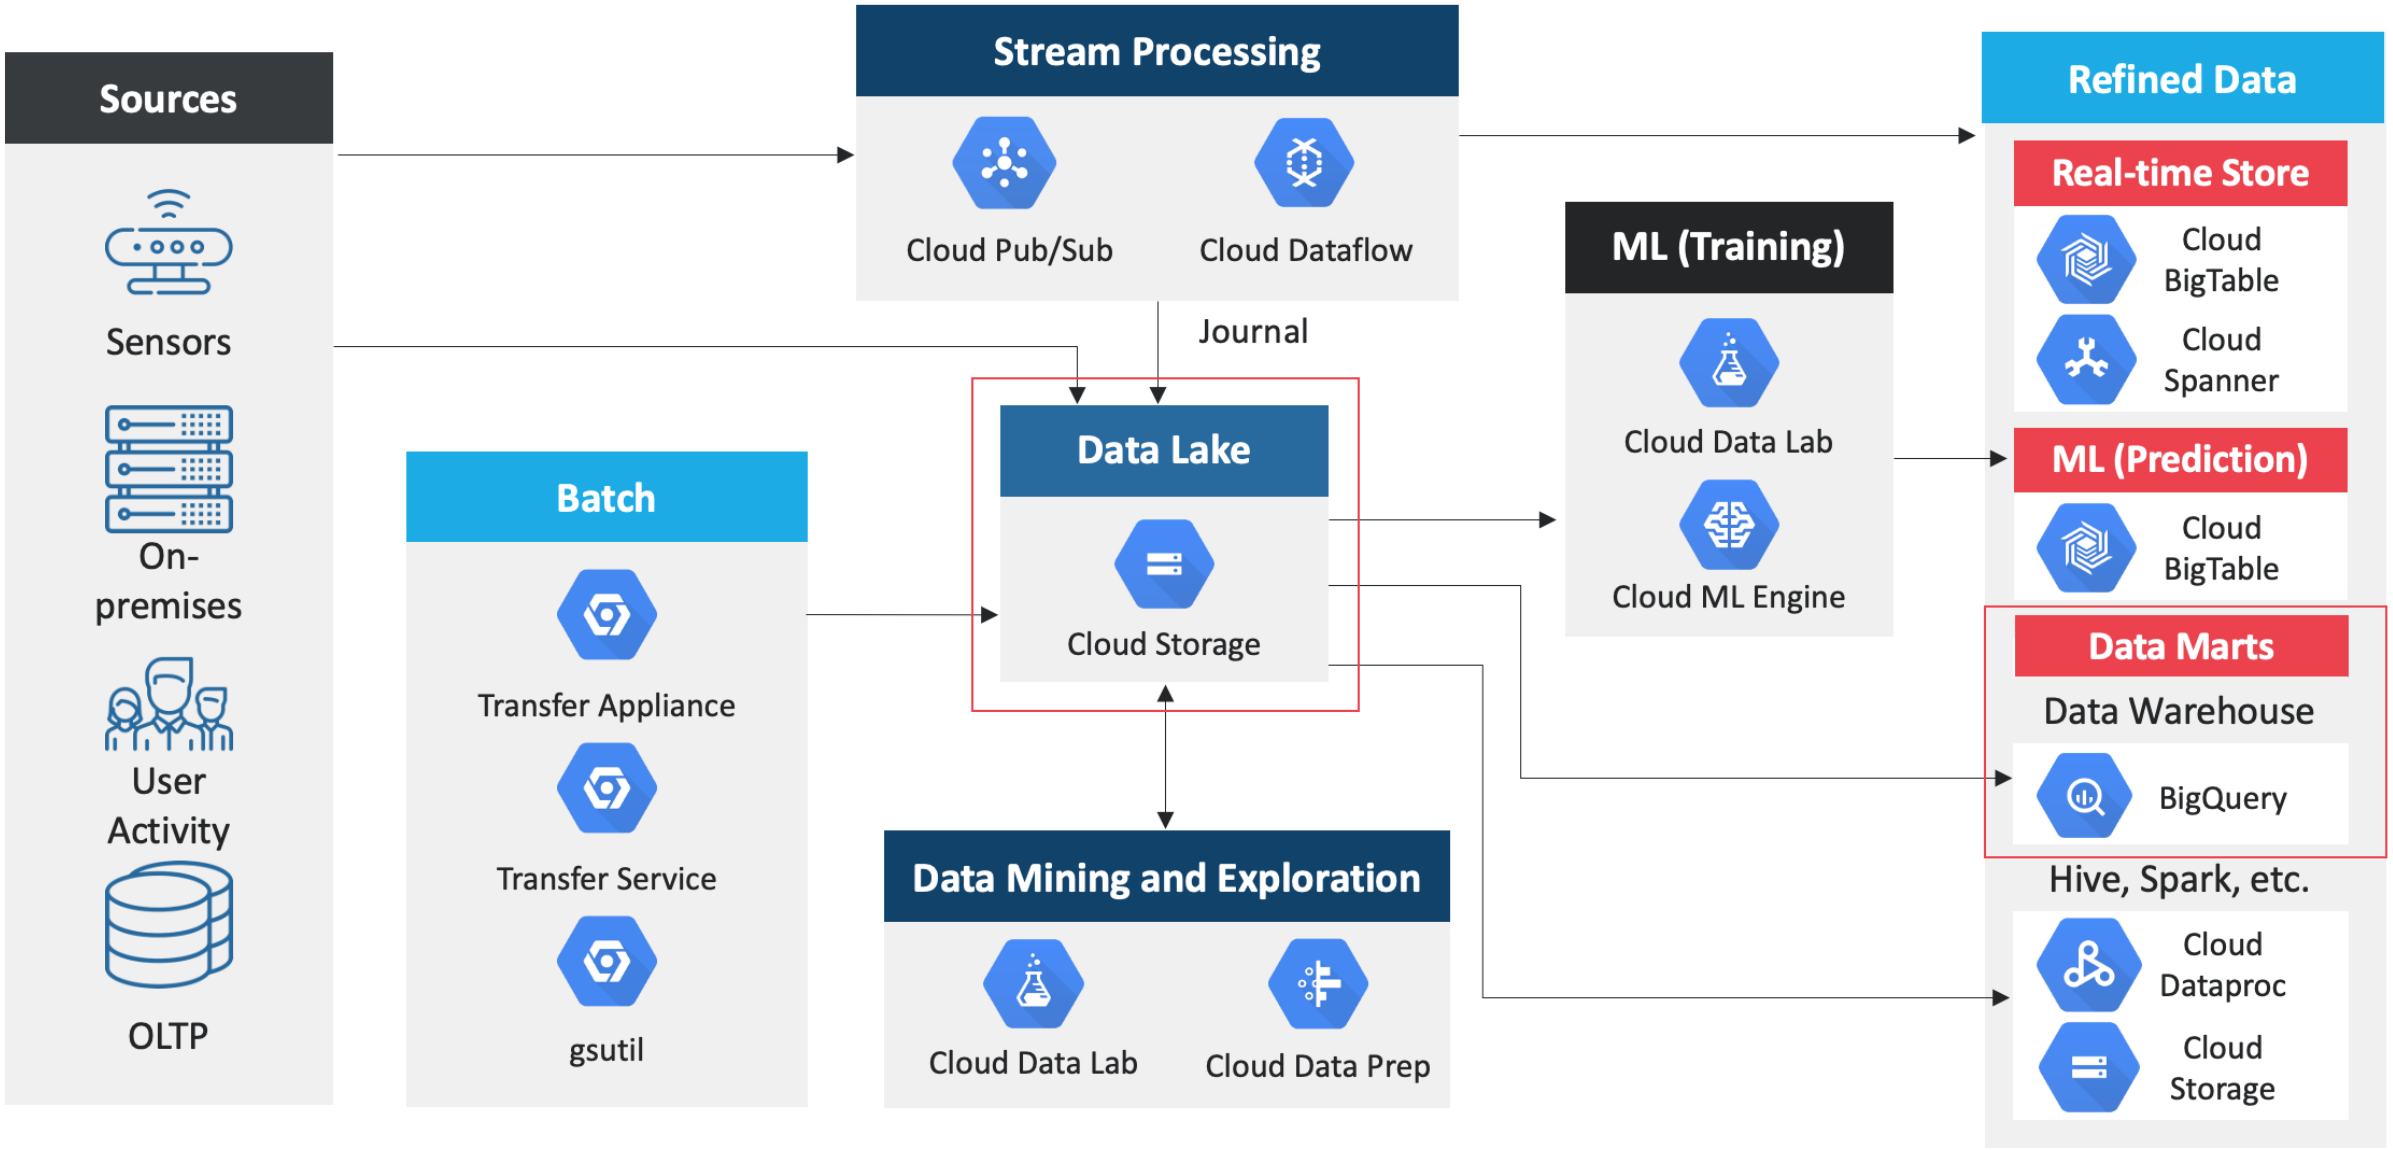

https://blog.miraclesoft.com/data-foundation-with-modernized-data-lake-data-warehouse/

Thank you

kgpark88@gmail.com